Analyse des Maladies Cardiaques

Projet de Datamining et Analyse de Données

Nom & Prénom : Farah Bensaid
Filière : BDIA – 2ème année cycle ingénieur

2025 – 2026

Table des matières

Chapitre 1 : Introduction Générale 4
1.1 Contexte du Projet 4
1.2 Problématique 4
1.3 Objectifs du Projet 4
1.4 Nature des données et positionnement scientifique 4
1.5 Méthodologie : CRISP-DM 4
1.6 Organisation du Rapport 5
Chapitre 2 : Présentation des Données 5
2.1 Dataset 1 — Heart Disease Cleveland UCI 6
2.2 Dataset 2 — Heart Attack Prediction Dataset 6
2.3 Liaison entre les Deux Datasets 7
Chapitre 3 : Analyse Descriptive et AFC 8
3.1 Distribution de la Variable Cible 8
3.2 Distributions des Variables Quantitatives 8
3.3 Boxplots par Classe 9
3.4 Variables Qualitatives vs Diagnostic 10
3.5 Matrice de Corrélation 10
3.6 Analyse Factorielle des Correspondances (AFC) 12
3.6.1 Principe Mathématique 12
3.6.2 AFC 1 — Activité Physique × Risque Cardiaque 13
3.6.3 AFC 2 — Régime Alimentaire × Niveau de Stress (tableau 3×3) 14
Chapitre 4 : ACP et Classification Non Supervisée 17
4.1 Analyse en Composantes Principales (ACP) 17
4.1.1 Principe 17
4.1.2 Matrice de Covariance 17
4.1.3 Scree Plot et Choix des Axes 17
4.1.4 Cercle des Corrélations 18
4.1.5 Plan Factoriel des Individus 19
4.2 Classification Non Supervisée 20
4.2.1 Méthode du Coude — Choix de K 20
4.2.2 Méthode A : K-Means Initial (K=3) 20
4.2.3 Méthode B : Classification Hiérarchique (CAH — Ward) 21
4.2.4 Méthode C : Classification Mixte 22
4.2.5 Méthode D : K-Means Affiné 22
4.2.6 Comparaison des Méthodes 22
Chapitre 5 : Méthodes Supervisées 25
5.1 Régression Linéaire — Prédiction de FC_Max 25
5.1.1 Modèle et Coefficients 25

5.1.2 Décomposition de la Variance 25
5.1.3 Évaluation du Modèle 26
5.2.1 Principe 27
5.2.2 Résultats et Évaluation 27
5.3 Arbre de Décision 28
5.3.1 Principe 28
5.3.2 Structure de l'Arbre 28
Règles principales observées : 29
5.3.3 Évaluation 29
Chapitre 6 : Comparaison des Modèles et Conclusion 31
6.1 Comparaison LDA vs Arbre de Décision 31
6.2 Synthèse Générale des Résultats 32
6.3 Variables Cliniques les Plus Importantes 32
6.4 Limites de l'étude 32
6.5 Conclusion Générale 33

Chapitre 1 : Introduction Générale

1.1 Contexte du Projet

Les maladies cardiovasculaires représentent la première cause de mortalité mondiale, responsables de plus de 17 millions de décès par an selon l'Organisation Mondiale de la Santé. La capacité à identifier précocement les patients à risque constitue un enjeu de santé publique majeur. Ce projet exploite deux jeux de données réels issus de Kaggle pour appliquer les méthodes de datamining et d'apprentissage automatique sur des données cliniques réelles.

1.2 Problématique

Comment, à partir de données cliniques hétérogènes, peut-on construire des modèles capables d'identifier les profils à risque, prédire des indicateurs cliniques, discriminer les patients sains des malades, et révéler des associations entre facteurs comportementaux et risque cardiaque ?

1.3 Objectifs du Projet

- Appliquer l'AFC pour explorer les associations entre variables qualitatives et le risque cardiaque.
- Réaliser une ACP pour réduire la dimensionnalité et visualiser la structure des données.
- Partitionner les patients en groupes homogènes via K-Means, CAH et Méthode Mixte.
- Construire un modèle de régression linéaire pour prédire la fréquence cardiaque maximale.
- Classifier les patients (Sain/Malade) par LDA et Arbre de Décision.
- Comparer les performances et identifier les variables cliniques les plus discriminantes.

1.4 Nature des données et positionnement scientifique

Les données utilisées dans ce projet sont des données réelles issues de sources publiques (UCI et Kaggle).
Il est important de noter que, contrairement à des données simulées, les données réelles présentent un niveau élevé de variabilité, de bruit et de facteurs non observés.

Ainsi, les performances des modèles obtenues dans ce projet ne doivent pas être évaluées uniquement en termes de précision, mais également en termes de cohérence clinique, d'interprétabilité et de robustesse.

Ce positionnement s'inscrit dans une démarche réaliste du datamining appliqué aux données biomédicales.

1.5 Méthodologie : CRISP-DM

Phase	Description	Application dans ce projet
1. Compréhension métier	Définir les objectifs	Prédiction du risque cardiaque
2. Compréhension données	Explorer et décrire	Analyse descriptive, corrélations

Phase	Description	Application dans ce projet
3. Préparation données	Nettoyer et transformer	Renommage, recodage, centrage-réduction
4. Modélisation	Appliquer les algorithmes	AFC, ACP, K-Means, CAH, LDA, Arbre
5. Évaluation	Mesurer les performances	Accuracy, R^2, Silhouette, Khi-2
6. Déploiement	Interpréter et conclure	Règles cliniques, recommandations

1.6 Organisation du Rapport

Le rapport est structuré en six chapitres : Introduction, Présentation des données, Analyse descriptive et AFC, ACP et Classification non supervisée, Méthodes supervisées, et Comparaison finale avec conclusion.

Chapitre 2 : Présentation des Données

2.1 Dataset 1 — Heart Disease Cleveland UCI

```
df1_raw = pd.read_csv("/kaggle/input/datasets/cherngs/heart-disease-cleveland-uci/heart_cleveland_upload.csv")

# Renommage des colonnes pour lisibilité
df1 = df1_raw.copy()
df1.columns = ['Age', 'Sexe', 'Type_Douleur', 'Tension', 'Cholesterol',
               'Glycemie_Jeun', 'ECG_Repos', 'FC_Max', 'Angine_Effort',
               'Depression_ST', 'Pente_ST', 'Nb_Vaisseaux', 'Thal',
               'Maladie']
```

Caractéristique	Valeur
Source	UCI Machine Learning Repository — Cleveland Clinic Foundation
Lien Kaggle	kaggle.com/datasets/cherngs/heart-disease-cleveland-uci
Patients	297 observations
Variables	14 variables (13 descripteurs + 1 cible)
Valeurs manquantes	Aucune
Variable cible	Maladie (0 = Sain / 1 = Malade)
Équilibre	54% Sains (160) vs 46% Malades (137)

Variable	Type	Description clinique
Age	Quantitative	Âge du patient (années)
Sexe	Qualitative	0 = Femme, 1 = Homme
Type_Douleur	Qualitative	0=Asymptomatique | 1=Angine atypique | 2=Non-angineux | 3=Angine typique
Tension	Quantitative	Tension artérielle au repos (mmHg)
Cholesterol	Quantitative	Cholestérol sérique (mg/dL)
FC_Max	Quantitative	Fréquence cardiaque maximale (bpm) → variable cible régression
Depression_ST	Quantitative	Dépression segment ST à l'effort → indicateur d'ischémie
Nb_Vaisseaux	Quantitative	Nombre de vaisseaux coronariens obstrués (0-3)
Maladie	Qualitative (CIBLE)	0 = Sain / 1 = Malade → variable cible classification

2.2 Dataset 2 — Heart Attack Prediction Dataset

```python
# ── Dataset 2 : Heart Attack Prediction ──────────────────
# 8763 patients mondiaux. Riche en variables qualitatives → AFC.
df2_raw = pd.read_csv("/kaggle/input/datasets/iamsouravbanerjee/heart-attack-prediction-dataset/heart_attack_prediction_dataset.csv")
df2 = df2_raw.copy()

# Créer variables catégorielles pour AFC
df2['Stress_Cat'] = pd.cut(df2['Stress Level'], bins=[0,3,6,10],
                           labels=['Stress_Faible','Stress_Modere','Stress_Eleve'])
df2['Activite_Cat'] = pd.cut(df2['Physical Activity Days Per Week'],
                             bins=[-1,1,3,7],
                             labels=['Sedentaire','Modere','Actif'])
df2['BMI_Cat'] = pd.cut(df2['BMI'], bins=[0,18.5,25,30,100],
                        labels=['Maigreur','Normal','Surpoids','Obesite'])
df2['Smoking_Label'] = df2['Smoking'].map({0:'Non_Fumeur', 1:'Fumeur'})
df2['Risque_Label']  = df2['Heart Attack Risk'].map({0:'Risque_Faible',
```

Caractéristique	Valeur
Source	Kaggle — iamsouravbanerjee/heart-attack-prediction-dataset
Patients	8 763 observations — 20 pays, 6 continents
Variables	26 variables
Valeurs manquantes	Aucune
Variable cible	Heart Attack Risk (0 = Faible / 1 = Élevé)
Distribution	64% Risque Faible (5624) / 36% Risque Élevé (3139)
Usage dans le projet	AFC uniquement (richesse en variables qualitatives)

Pour l'AFC, trois variables continues ont été discrétisées :

Variable créée	Source	Modalités
Stress_Cat	Stress Level (0-10)	Stress_Faible (0-3) / Stress_Modere (4-6) / Stress_Eleve (7-10)
Activite_Cat	Physical Activity Days/Week	Sedentaire (0-1) / Modere (2-3) / Actif (4-7)
BMI_Cat	BMI	Maigreur (<18,5) / Normal (18,5-25) / Surpoids (25-30) / Obesite (>30)

2.3 Liaison entre les Deux Datasets

Les deux datasets sont complémentaires autour d'un objectif commun : comprendre le risque cardiovasculaire. Le Dataset 1 fournit des mesures cliniques précises sur 297 patients hospitalisés, utilisées pour toutes les méthodes quantitatives. Le Dataset 2, avec ses 8763 patients internationaux, est riche en variables comportementales et qualitatives, idéal pour l'AFC.

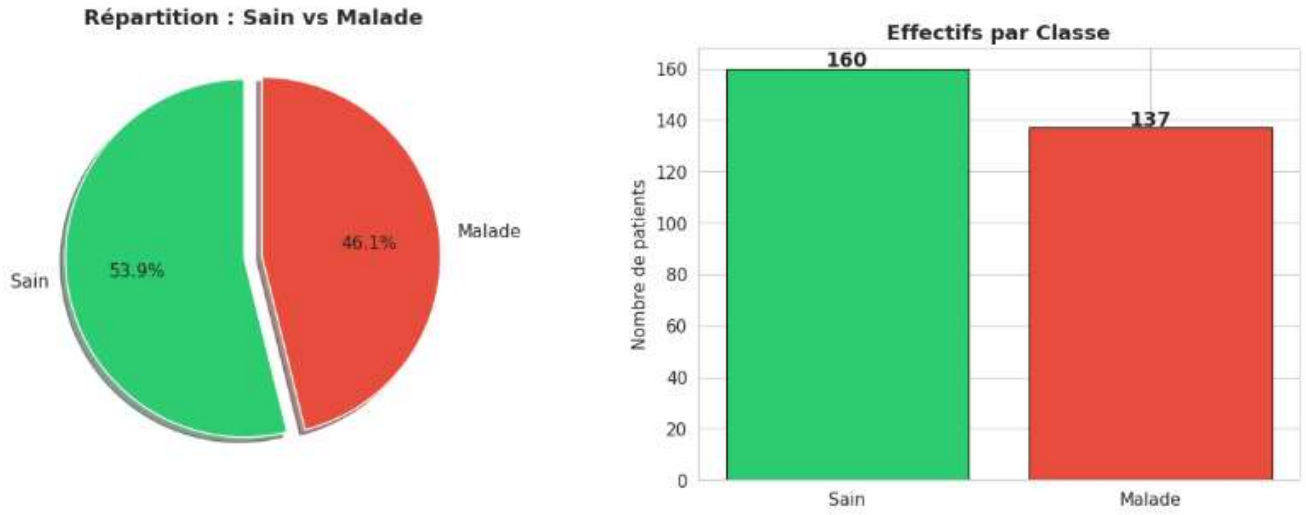
La liaison conceptuelle est une chaîne causale : les facteurs comportementaux du Dataset 2 (tabagisme, sédentarité, stress) sont précisément ceux qui, sur le long terme, produisent les altérations cliniques mesurées dans le Dataset 1 (depression ST, obstruction vasculaire, FC_Max réduite). Les deux datasets racontent deux niveaux d'une même réalité médicale.

Chapitre 3 : Analyse Descriptive et AFC

3.1 Distribution de la Variable Cible

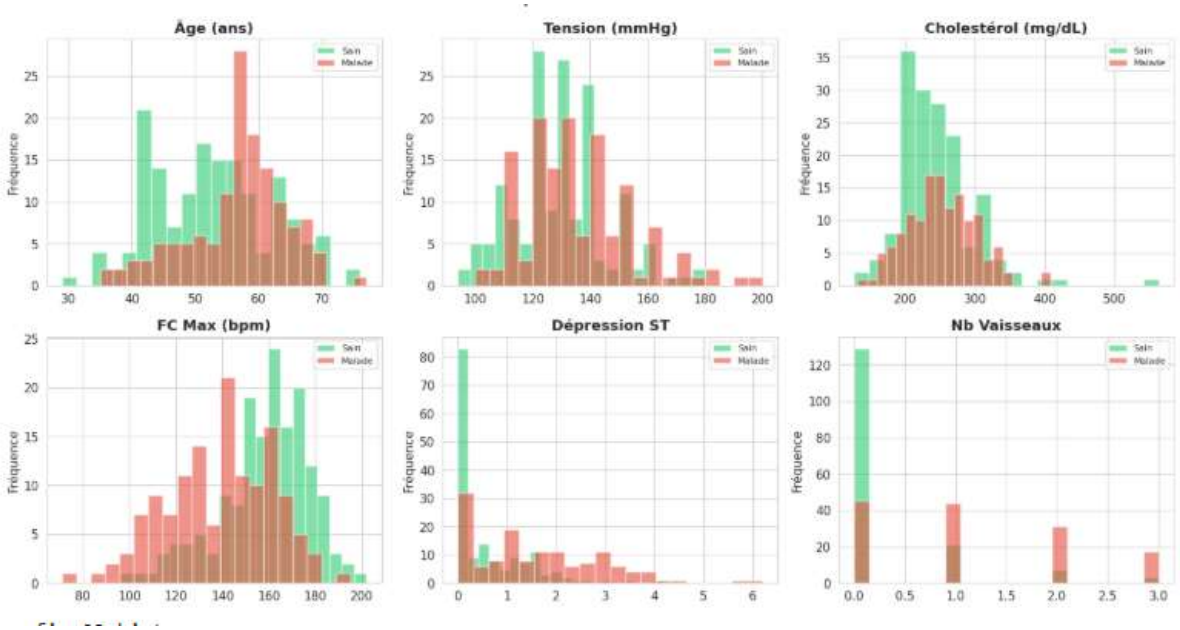
```
# ── 2.1 Distribution de la variable cible ──────────────────
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
colors_cible = ['#2ecc71', '#e74c3c']
df1['Maladie_Label'].value_counts().plot.pie(
    ax=axes[0], autopct='%1.1f%%', colors=colors_cible,
    startangle=90, shadow=True, explode=[0.05, 0.05])
axes[0].set_title("Répartition : Sain vs Malade", fontweight='bold')
axes[0].set_ylabel("")

counts_cible = df1['Maladie_Label'].value_counts()
bars = axes[1].bar(counts_cible.index, counts_cible.values,
                   color=colors_cible, edgecolor='black', linewidth=0.8)
for bar, val in zip(bars, counts_cible.values):
    axes[1].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 1,
                 str(val), ha='center', fontweight='bold', fontsize=13)
axes[1].set_title("Effectifs par Classe", fontweight='bold')
axes[1].set_ylabel("Nombre de patients")
plt.suptitle("Dataset 1 — Variable Cible : Maladie Cardiaque",
             fontsize=13, fontweight='bold')
plt.tight_layout()
plt.savefig("fig_01_distribution_cible.png", bbox_inches='tight')
plt.show()
print("→ fig_01_distribution_cible.png")
```



Le dataset est quasi-équilibré avec 53,9% de patients sains et 46,1% de malades. Cet équilibre est favorable à la modélisation car il évite le biais de classe majoritaire, rendant inutile tout rééchantillonnage (SMOTE). La représentativité des deux classes garantit que les modèles apprendront de manière équitable les deux profils.

3.2 Distributions des Variables Quantitatives

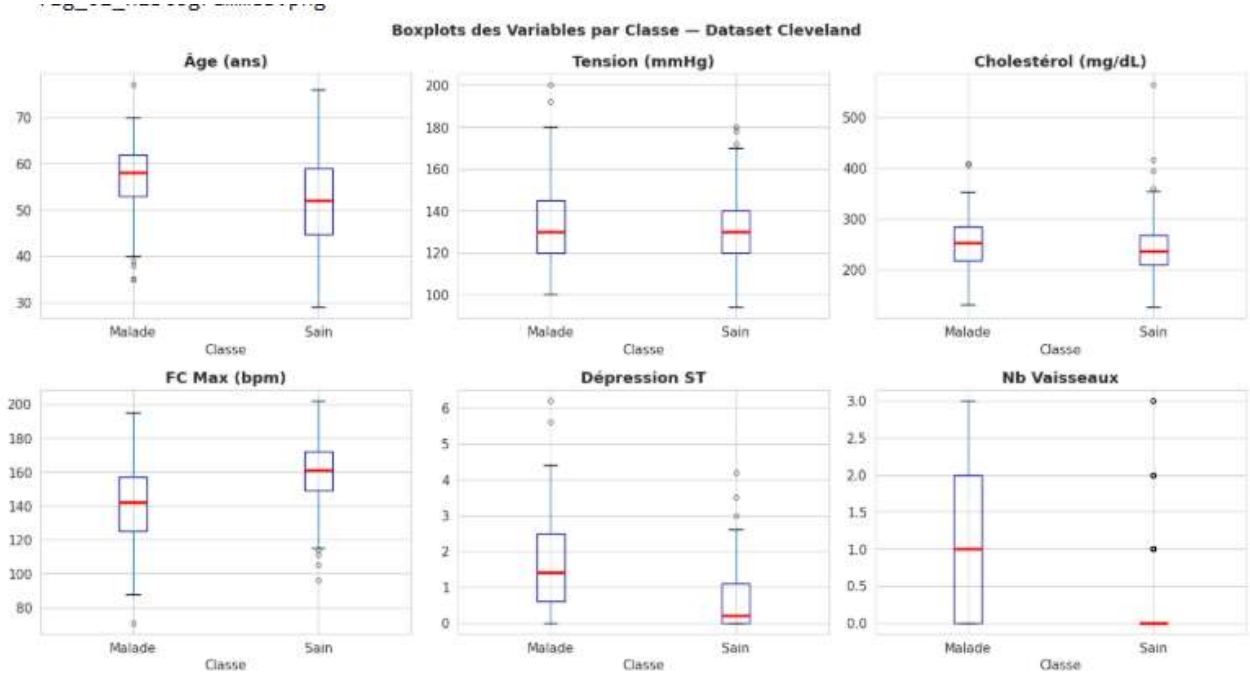


Les patients malades présentent une fréquence cardiaque maximale (FC_Max) nettement plus faible que les patients sains (139 bpm contre 159 bpm en moyenne), ainsi qu'une dépression du segment ST significativement plus élevée (1,59 contre 0,60). Ces deux variables apparaissent comme les plus discriminantes visuellement**,** ce qui est cohérent avec leur rôle clinique dans l'évaluation de l'ischémie myocardique.
Le nombre de vaisseaux (Nb_Vaisseaux) est également fortement discriminant, avec une moyenne plus élevée chez les patients malades (1,15 vs 0,28), ce qui reflète une atteinte coronarienne plus importante.
En revanche, le **cholestérol** montre une différence moyenne relativement faible entre les deux groupes (251 vs 243 mg/dL), avec un fort chevauchement des distributions. Cela suggère qu'il **n'est pas un bon prédicteur pris isolément**, un résultat cohérent avec la littérature clinique où le cholestérol doit être interprété en combinaison avec d'autres facteurs de risque.

les patients malades sont en moyenne **légèrement plus âgés** et présentent une **tension artérielle un peu plus élevée**, mais ces variables sont moins discriminantes que la FC_Max, la dépression ST et le nombre de vaisseaux.
Ces observations confirment que les variables liées directement à la fonction cardiaque (FC_Max, Depression_ST, Nb_Vaisseaux) sont plus discriminantes que les facteurs indirects (cholestérol, tension).

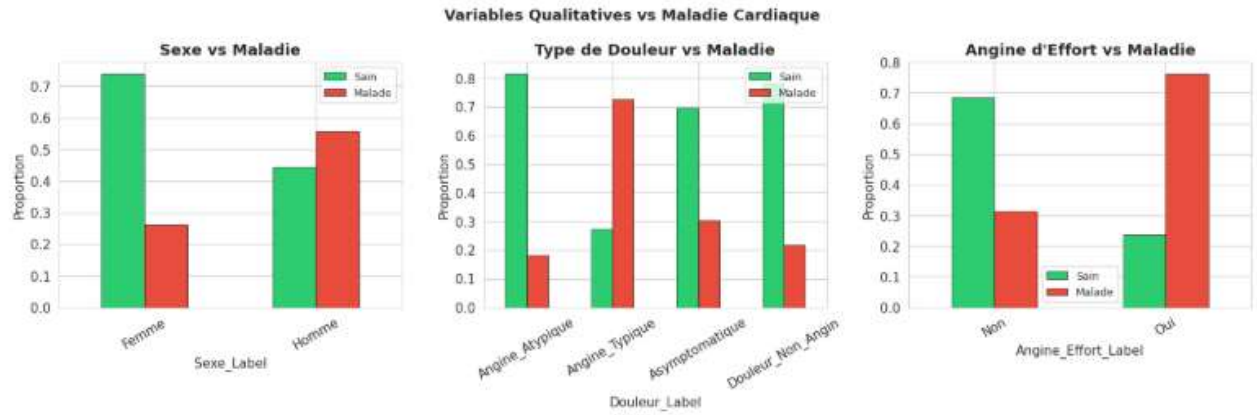
Cela suggère que les indicateurs fonctionnels et anatomiques sont plus pertinents pour la détection de la maladie que les facteurs de risque isolés, ce qui est cohérent avec la littérature médicale.

3.3 Boxplots par Classe



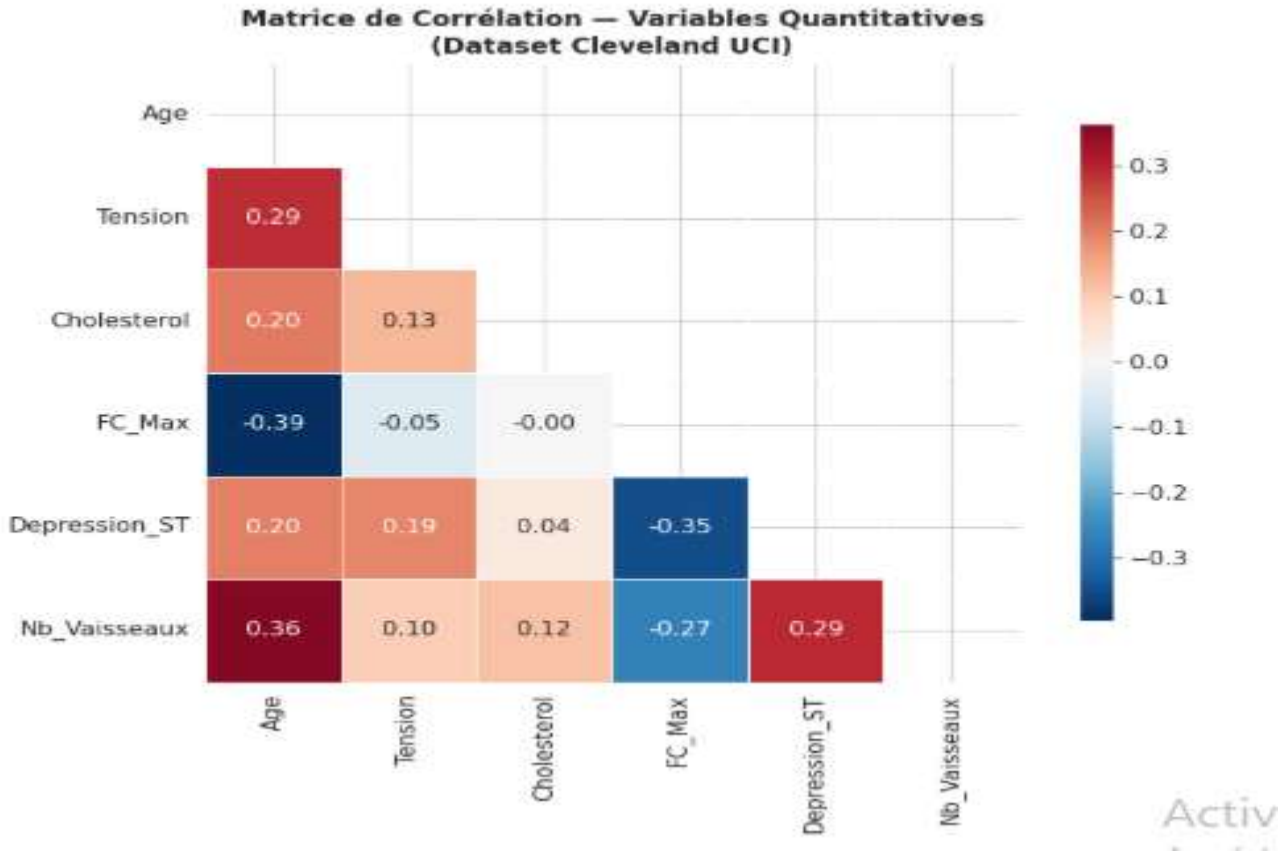
Les boîtes à moustaches confirment les différences observées dans les histogrammes. Les médianes de FC_Max sont nettement séparées entre les deux groupes. La Depression_ST montre de nombreux outliers pour les patients malades, reflétant la variabilité dans la sévérité de l'ischémie. La Tension est légèrement plus élevée chez les malades mais avec un chevauchement important, limitant son pouvoir discriminant isolément.

3.4 Variables Qualitatives vs Diagnostic



Les hommes sont proportionnellement plus nombreux parmi les patients malades, suggérant un **risque plus élevé** que chez les femmes. Le type de douleur thoracique est discriminant : les formes **asymptomatiques** sont fréquemment associées à la maladie, ce qui peut refléter des cas d'ischémie silencieuse. L'**angine d'effort** est également fortement associée à la maladie, mais ne peut pas être considérée comme pathognomonique, car elle est aussi observée chez certains patients sains.

3.5 Matrice de Corrélation



La corrélation de Pearson mesure la force et le sens des relations linéaires entre variables :

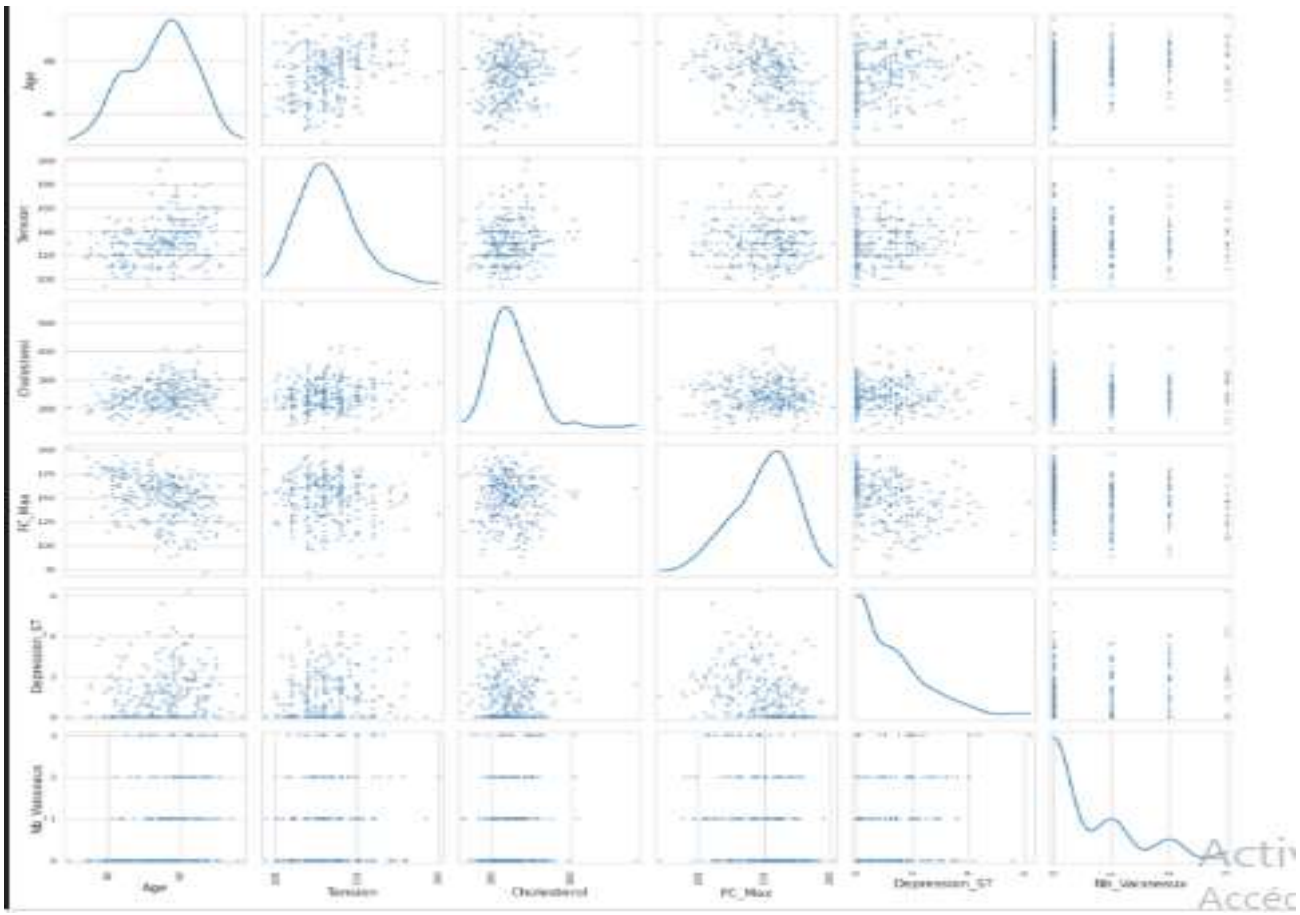
$$r(X,Y) = Cov(X,Y) / (\sigma_X \times \sigma_Y) \quad \text{avec } r \in [-1, +1]$$

Trois corrélations importantes se dégagent.

La corrélation Age ↔ FC_Max (r = −0,40) est la plus forte : la fréquence cardiaque maximale diminue avec l'âge, confirmant empiriquement la formule clinique FC_Max ≈ 220 − Age.

La corrélation Age ↔ Nb_Vaisseaux (r = +0,36) traduit l'artériosclérose progressive avec le vieillissement.

La corrélation FC_Max ↔ Depression_ST (r = −0,35) indique qu'une dépression ST élevée s'accompagne d'une FC_Max réduite, deux marqueurs convergents d'ischémie coronarienne.



La scatter matrix visualise simultanément toutes les relations entre paires de variables. La relation Age-FC_Max est la plus lisible avec une tendance linéaire décroissante nette. Les nuages Age-Nb_Vaisseaux et Depression_ST-FC_Max confirment visuellement les corrélations calculées. Les diagonales (densité KDE) montrent que la plupart des variables ont des distributions approximativement normales, justifiant l'usage des méthodes paramétriques.

3.6 Analyse Factorielle des Correspondances (AFC)

3.6.1 Principe Mathématique

L'AFC analyse l'association entre deux variables qualitatives via un tableau de contingence. Le profil ligne de la modalité i est la répartition conditionnelle des colonnes pour cette ligne :

L'écart entre le profil ligne et le profil marginal colonne (f_+j = n_+j / n) mesure l'association. Si tous les profils lignes sont égaux au profil marginal, les deux variables sont indépendantes.

```python
# ── Tableau AFC 1 : Tabagisme × Risque (2×2 — enrichi) ──────────
# On utilise le Stress_Cat (3 modalités) × Risque pour un tableau plus riche
print("\n>>> AFC 1 : Stress_Cat × Risque_Cardiaque")
D_afc1 = pd.crosstab(df2['Stress_Cat'], df2['Risque_Label'])
print(D_afc1)

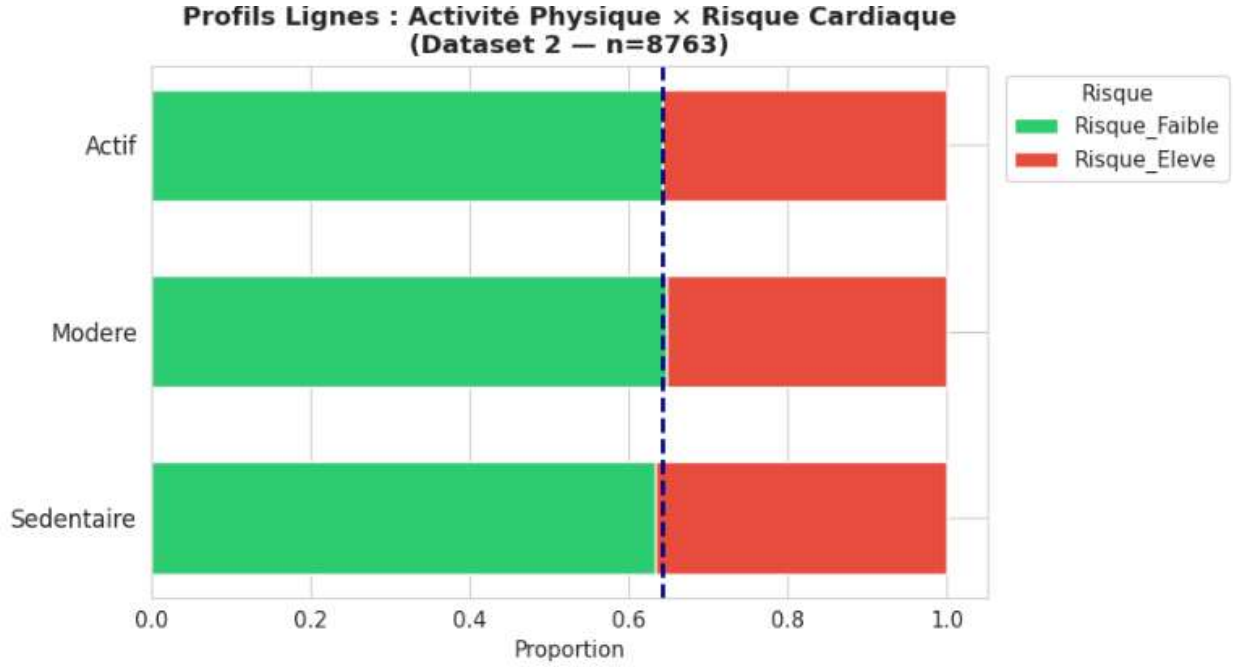
# ── Tableau AFC 2 : Diet × Stress_Cat (tableau 3×3) ─────────────
print("\n>>> AFC 2 : Diet × Stress_Cat (tableau 3×3)")
D_afc2 = pd.crosstab(df2['Diet'], df2['Stress_Cat'])
print(D_afc2)

# ── AFC principale : Smoking × Risque + Activite × Risque ────────
print("\n>>> AFC principale : Activite_Cat × Risque_Label")
D = pd.crosstab(df2['Activite_Cat'], df2['Risque_Label'])
D = D[['Risque_Faible', 'Risque_Eleve']]
print(D)

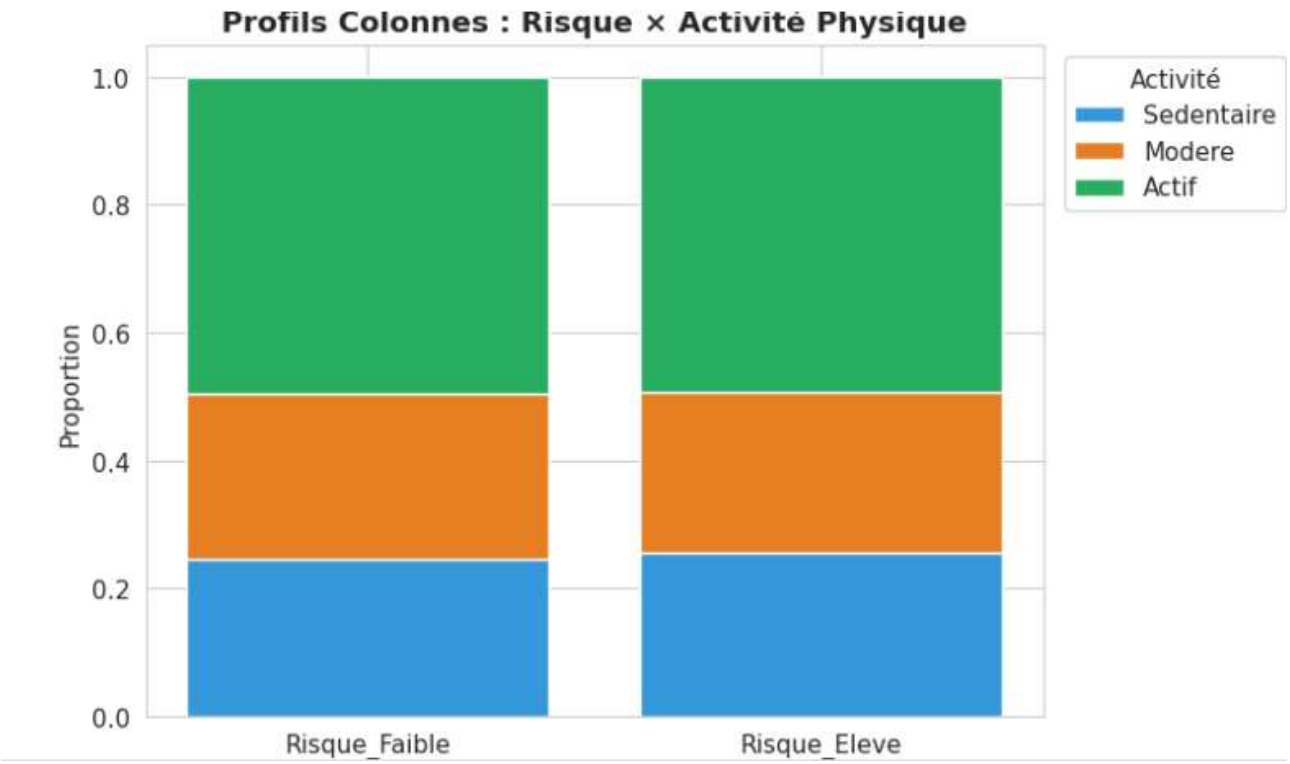
# ── 3.1 Totaux marginaux ─────────────────────────────────────────
tot_lig = np.sum(D.values, axis=1)
tot_col = np.sum(D.values, axis=0)
n_total = np.sum(D.values)
print(f"\n>>> Totaux lignes (effectifs par activité) : {dict(zip(D.index, tot_lig))}")
print(f">>> Totaux colonnes (effectifs par risque)  : {dict(zip(D.columns, tot_col))}")
print(f">>> Effectif total : {n_total}")
```

Activer Wi
Accédez aux

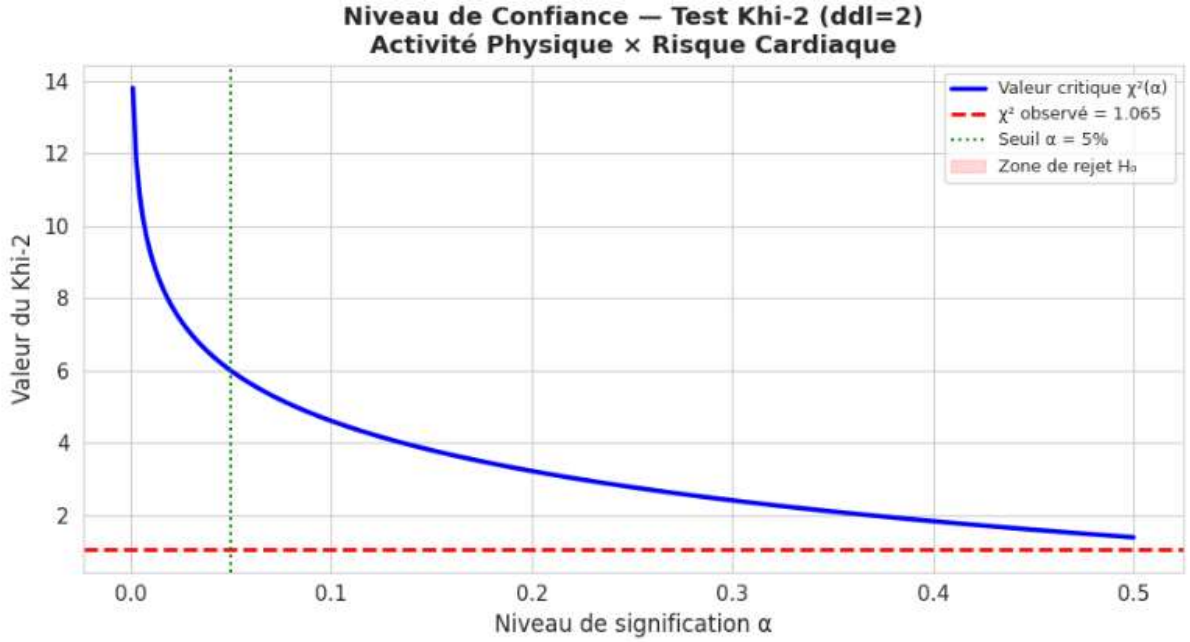
3.6.2 AFC 1 — Activité Physique × Risque Cardiaque



Les trois profils lignes (Sédentaire : 63,3% faible risque / Modéré : 64,7% / Actif : 64,3%) sont quasi-identiques entre eux et très proches du profil marginal (64,2%). Les barres des trois groupes se superposent visuellement, indiquant l'absence de différenciation selon le niveau d'activité physique.



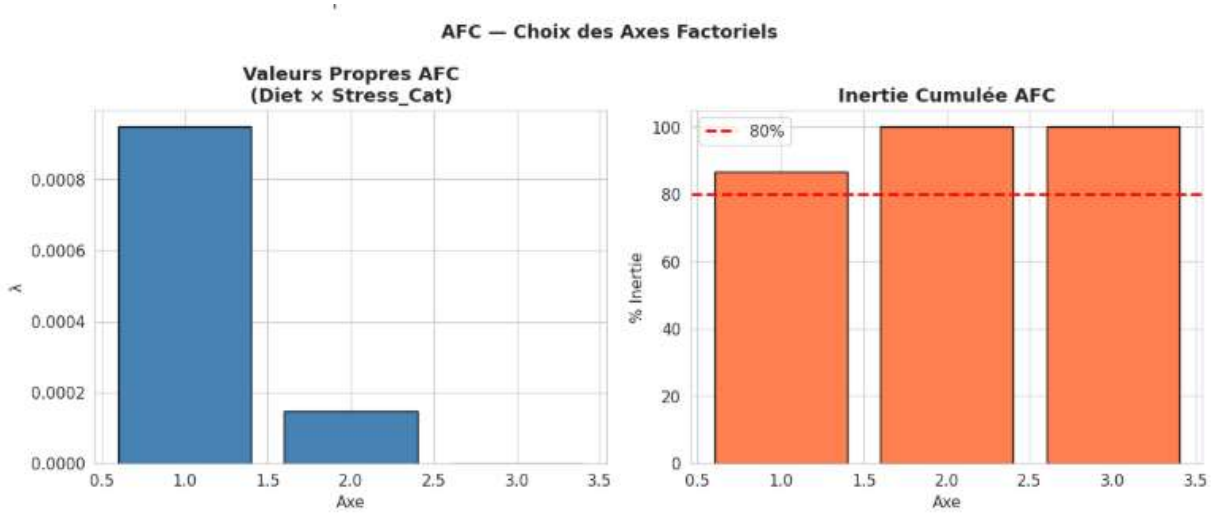
Les profils colonnes confirment la même observation : la distribution de l'activité physique est pratiquement identique dans les groupes Risque Faible et Risque Élevé (~49% Actifs dans les deux cas). Le test du Khi-2 formalise ce constat :



Le test donne $\chi^2 = 1{,}065$ pour 2 degrés de liberté, soit une p-value = 0,587. La valeur observée (ligne rouge) se situe très en-dessous de la valeur critique à 5% (χ^2_critique = 5,99), dans la zone de non-rejet de H_0 (zone blanche).

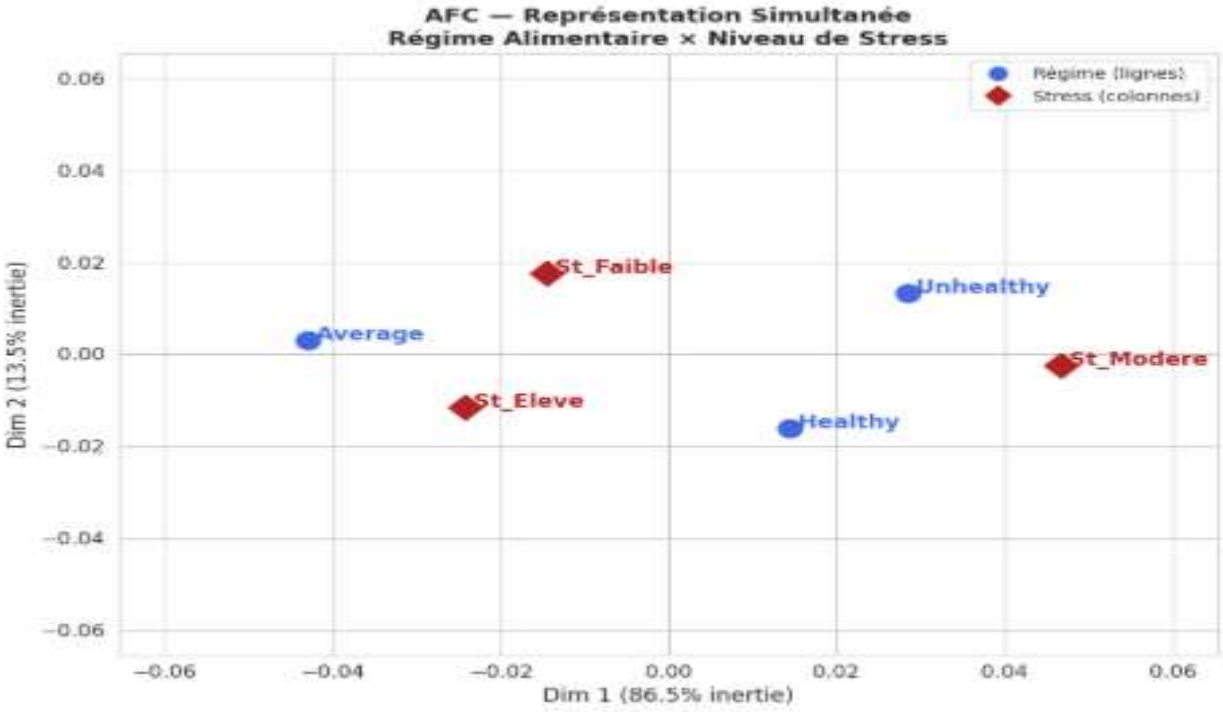
Conclusion : on ne rejette pas H_0, il n'existe pas d'association statistiquement significative entre le niveau d'activité physique et le risque cardiaque dans ce dataset. Ce résultat contre-intuitif peut s'expliquer par des biais de mesure (déclaratif) ou des confondants non contrôlés dans cette large étude internationale.

3.6.3 AFC 2 — Régime Alimentaire × Niveau de Stress (tableau 3×3)



Pour ce tableau 3×3 (Diet × Stress_Cat), le test Khi-2 donne χ^2 = 9,608 avec 4 degrés de liberté et une p-value = 0,048 < 0,05.

Conclusion : on rejette H_0 : il existe une association significative entre le régime alimentaire et le niveau de stress. L'Axe 1 de l'AFC capte 86,54% de l'inertie totale (λ_1 = 0,000949), ce qui signifie qu'un seul axe suffit à résumer l'essentiel de la structure d'association.



Dans le biplot de l'analyse factorielle des correspondances (AFC), les deux premières dimensions expliquent **86,5 %** et **13,5 %** de l'inertie, soit **100 % de l'information**, ce qui permet une représentation fidèle des données dans le plan.

La **dimension 1 (86,5 %)** constitue l'axe principal de différenciation. Elle oppose :

- à droite : les régimes **Healthy** (≈ +0,02) et **Unhealthy** (≈ +0,03), associés au **stress modéré (St_Modere ≈ +0,05)**
- à gauche : le régime **Average (≈ -0,04)**, ainsi que les niveaux de stress **élevé (St_Eleve ≈ -0,02)** et **faible (St_Faible ≈ -0,015)**

Cependant, l'interprétation des associations doit se faire à partir de la **proximité réelle entre points** :

- Le régime **Healthy** est **relativement proche de St_Modere**, suggérant une **légère association**
- Le régime **Unhealthy** est également du même côté que **St_Modere**, mais reste à une distance modérée → association faible
- Le régime **Average** est **assez éloigné de St_Eleve**, ce qui ne permet pas de conclure à une association forte

Par ailleurs, toutes les modalités sont situées **près de l'origine**, ce qui reflète une **faible inertie absolue (≈ 0,001097)**. Cela indique que les écarts à l'indépendance sont **très faibles en valeur absolue**.

Ainsi, malgré une **significativité statistique probable (n = 8763)**, les relations entre régime alimentaire et niveau de stress restent **faibles en intensité pratique**.

Chapitre 4 : ACP et Classification Non Supervisée

4.1 Analyse en Composantes Principales (ACP)

4.1.1 Principe

L'ACP recherche les directions de variance maximale dans les données. Après centrage-réduction (moyenne=0, écart-type=1), elle décompose la matrice de covariance Σ en vecteurs propres :

$$\Sigma \times v_k = \lambda_k \times v_k \quad (k = 1, ..., p)$$

La corrélation entre la variable j et l'axe k est donnée par :

$$\text{cor}(X_j, CP_k) = a_{kj} \times \sqrt{\lambda_k} \quad \text{(corrélation variable-axe)}$$

4.1.2 Matrice de Covariance

La matrice de covariance des données centrées-réduites est équivalente à la matrice de corrélation. Trois covariances fortes ressortent : Age ↔ FC_Max (r = −0,396) — relation négative forte validant FC_Max ≈ 220 − Age. Age ↔ Nb_Vaisseaux (r = +0,363) — artériosclérose progressive. FC_Max ↔ Depression_ST (r = −0,349) — deux marqueurs convergents d'ischémie.

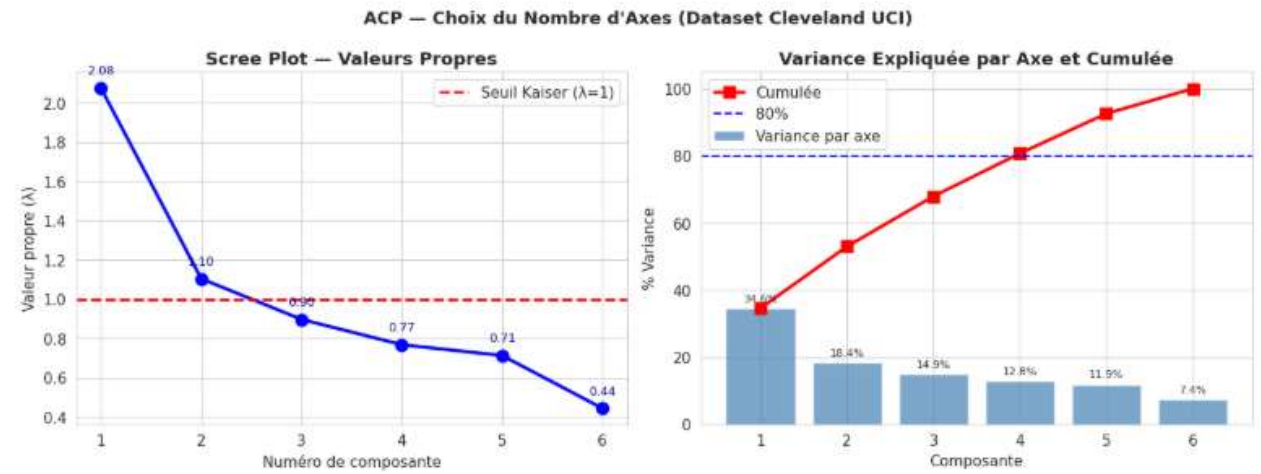
```
# ── 4.2 Matrice de covariance ──────────────────────────────
cov_matrix = np.cov(data_cr.T)
df_cov = pd.DataFrame(cov_matrix, index=vars_quant, columns=vars_quant)
print("\n>>> Matrice de Covariance (= Corrélation sur données CR) :")
print(df_cov.round(4))
print("\n>>> Relations fortes détectées (|r| > 0.3) :")
for i in range(len(vars_quant)):
    for j in range(i+1, len(vars_quant)):
        if abs(cov_matrix[i,j]) > 0.3:
            s = "POSITIVE" if cov_matrix[i,j] > 0 else "NÉGATIVE"
            print(f"    {vars_quant[i]} ↔ {vars_quant[j]} : "
                  f"{cov_matrix[i,j]:.3f} → {s}")

# ── 4.3 Application de l'ACP ──────────────────────────────
acp = PCA(n_components=p)
acp.fit(data_cr)
eigval = (n-1)/n * acp.explained_variance_

print("\n>>> Valeurs propres et variance expliquée :")
for i, (ev, pct, cum) in enumerate(zip(
        eigval,
        acp.explained_variance_ratio_*100,
        np.cumsum(acp.explained_variance_ratio_)*100)):
    kaiser = "✅ RETENU (λ>1)" if ev >= 1 else "❌ rejeté"
    print(f"    Axe {i+1}: λ={ev:.4f} | {pct:.2f}% | cumulé={cum:.2f}% | {kaiser}")
```

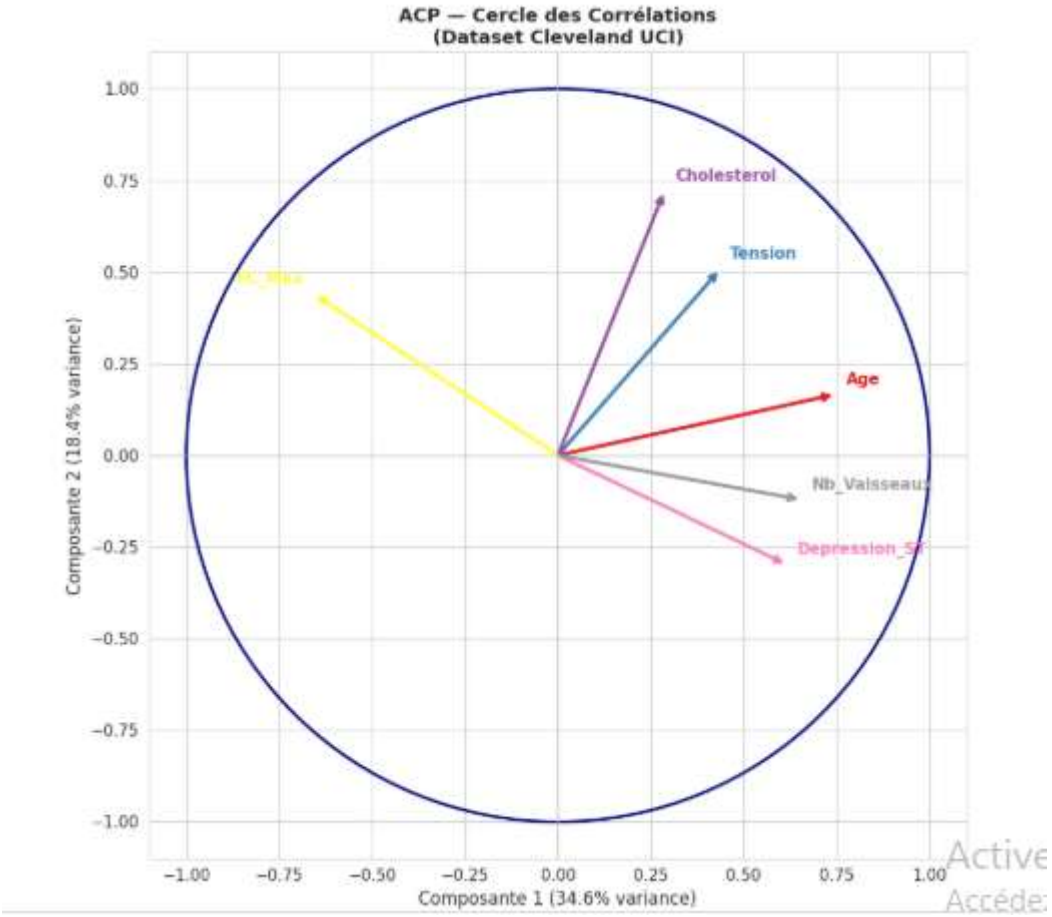
Activer Wi
Accédez aux

4.1.3 Scree Plot et Choix des Axes



Selon la règle de Kaiser (retenir les axes avec λ > 1), deux axes sont retenus. L'Axe 1 explique 34,59% de la variance (λ_1 = 2,075) et l'Axe 2 explique 18,40% (λ_2 = 1,104), soit 52,98% cumulé. Le coude du scree plot confirme visuellement ce choix : l'inflexion nette entre l'Axe 2 et l'Axe 3 (λ_3 = 0,897 < 1) indique que l'information supplémentaire devient marginale au-delà de deux composantes.

4.1.4 Cercle des Corrélations



Le cercle des corrélations révèle deux groupes opposés sur l'Axe 1

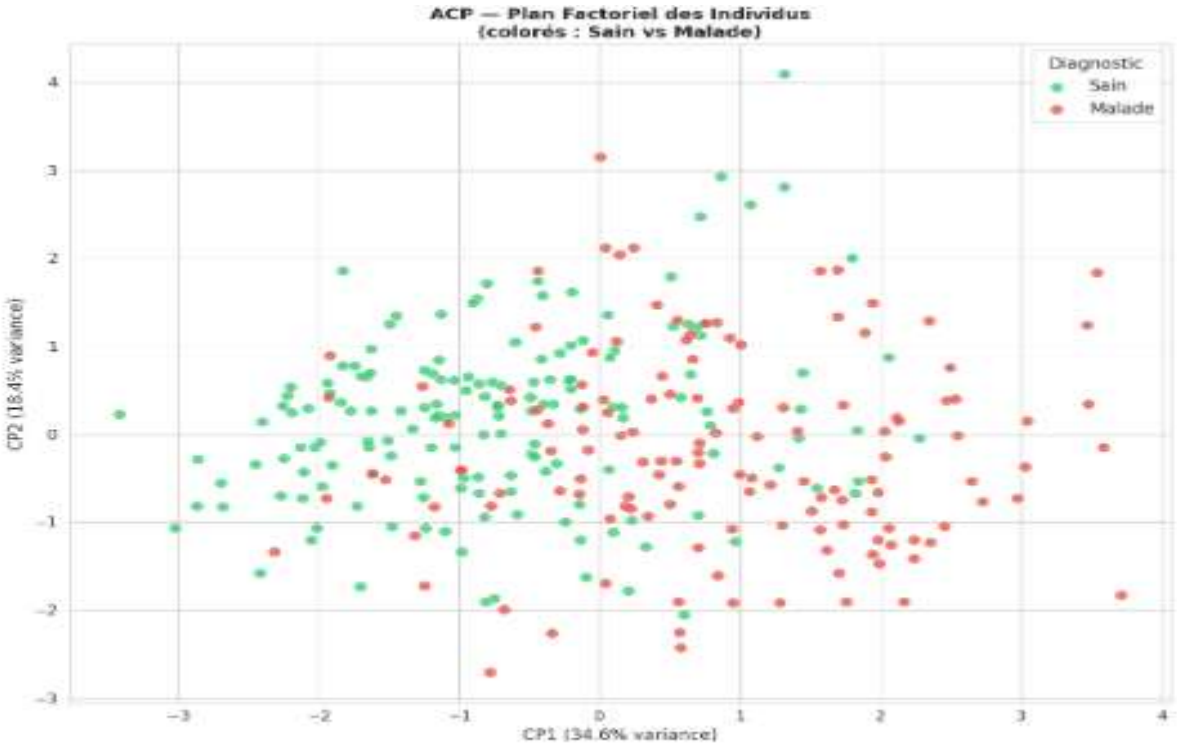
Du côté positif : Age (cor = +0,747), Nb_Vaisseaux (+0,656) et Depression_ST (+0,617) — variables qui augmentent avec la sévérité de la maladie.

Du côté négatif : FC_Max (cor = −0,658) — qui diminue avec la sévérité.

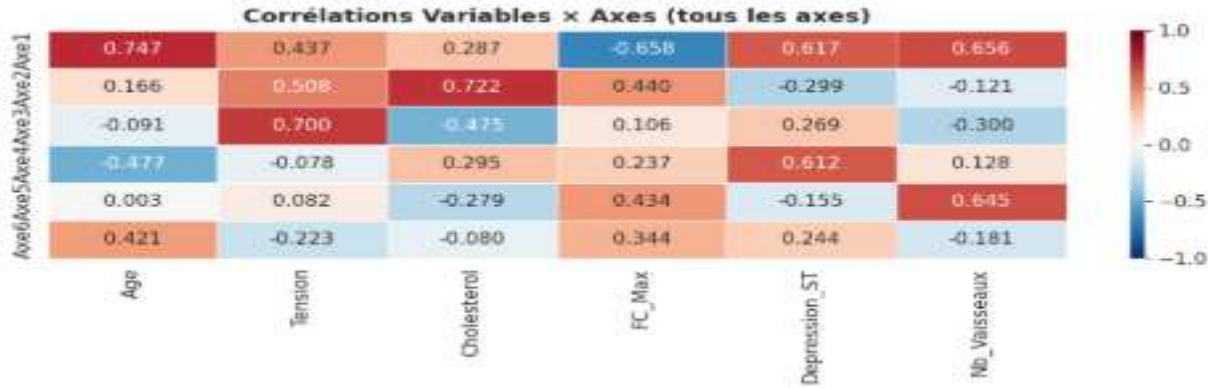
CP1 est donc un axe de « sévérité cardiaque ».

CP2 est principalement dominé par le Cholestérol (+0,722) et la Tension (+0,508), formant un axe « métabolique » indépendant du premier. Les variables proches du bord du cercle unité (Age, Nb_Vaisseaux, FC_Max) sont bien représentées dans ce plan.

4.1.5 Plan Factoriel des Individus



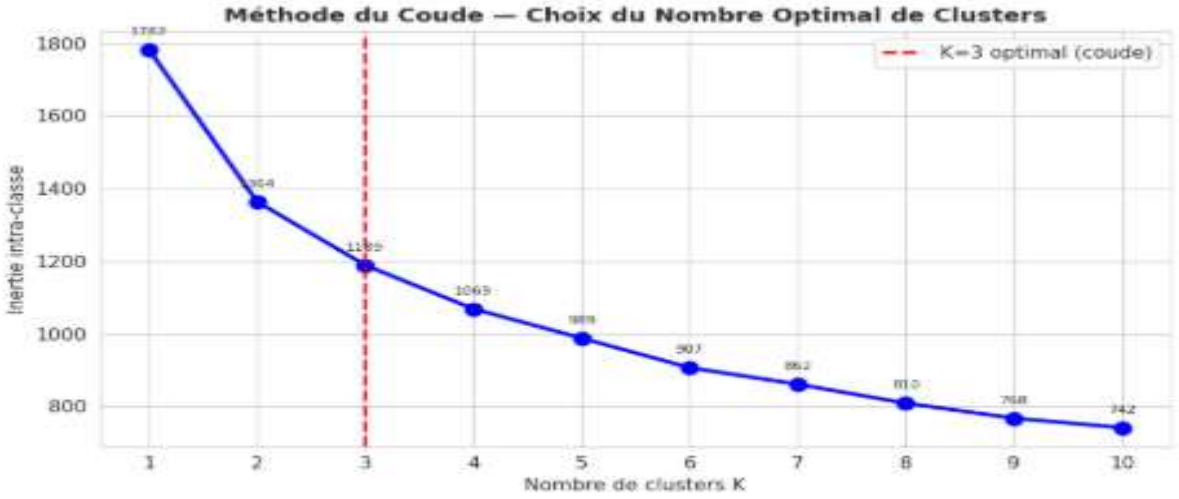
Le plan factoriel montre une séparation partielle entre patients Sains et Malades. Les malades tendent à se concentrer dans la partie droite du plan (CP1 > 0), correspondant aux profils âgés avec dépression ST élevée et peu de capacité cardiaque. Les sains sont davantage à gauche (CP1 < 0) avec des FC_Max élevées. Le chevauchement résiduel visible dans la zone centrale explique pourquoi aucun modèle ne peut atteindre 100% d'accuracy — certains patients malades ont des profils proches des sains et vice-versa.



La heatmap confirme les contributions de chaque variable aux axes. Sur l'Axe 3, la Tension domine (cor = +0,700), représentant un axe d'hypertension isolé. Sur l'Axe 4, la Depression_ST reprend de l'importance (+0,612), reflétant une dimension résiduelle d'ischémie non capturée par les deux premiers axes.

4.2 Classification Non Supervisée

4.2.1 Méthode du Coude — Choix de K



Le graphique de la méthode du coude montre une diminution rapide de l'inertie entre K=1 et K=3, puis une décroissance plus progressive au-delà. Le point K=3 apparaît ainsi comme un bon compromis entre réduction de l'inertie et simplicité du modèle.
Ainsi, on retient K=3 clusters.

4.2.2 Méthode A : K-Means Initial (K=3)

L'algorithme K-Means partitionne les données en trois groupes de tailles respectives 134, 74 et 89, avec une inertie intra-classe de 1189,35.

L'analyse des clusters montre :

- Un cluster de patients jeunes avec une fréquence cardiaque maximale élevée et peu d'obstruction, correspondant à un profil sain.
- Un cluster de patients âgés avec une dépression ST élevée et un nombre important de vaisseaux obstrués, indiquant un profil à risque élevé.
- Un troisième cluster intermédiaire correspondant à un profil de risque modéré.

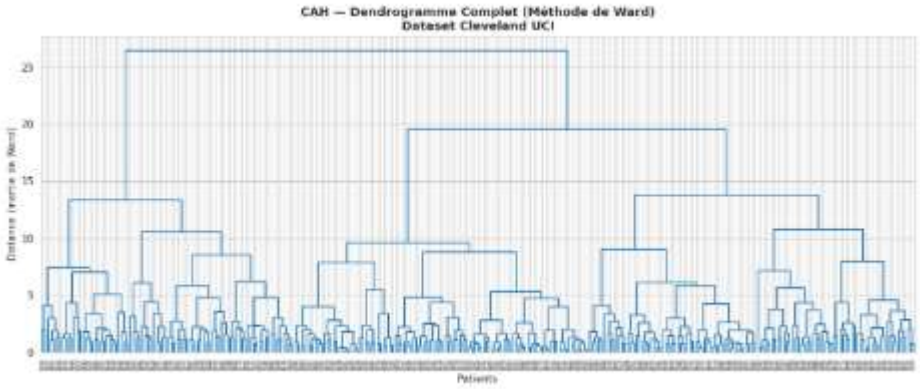
```
print(f"MÉTHODE A : K-MEANS INITIAL (K={K_opt})")
print(f"{'='*60}")

kmeans_init = cluster.KMeans(n_clusters=K_opt, random_state=42, n_init=10)
kmeans_init.fit(data_cr)
labels_km = kmeans_init.labels_

print("\n>>> Répartition par cluster :")
vc = pd.Series(labels_km).value_counts().sort_index()
for k, cnt in vc.items():
    print(f"    Cluster {k} : {cnt} patients")

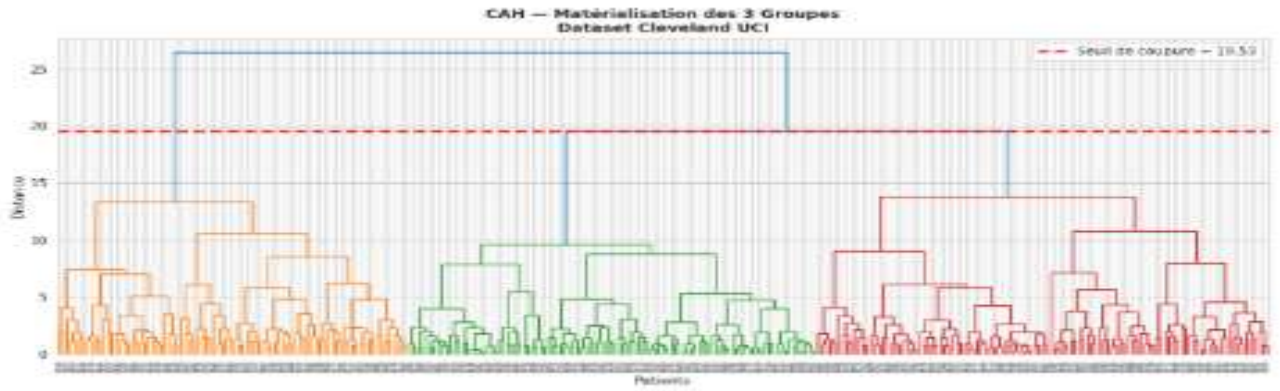
print("\n>>> Centres des clusters (valeurs originales) :")
centers_orig = (kmeans_init.cluster_centers_ *
                data_quant.std().values + data_quant.mean().values)
df_centers = pd.DataFrame(centers_orig, columns=vars_quant,
                          index=[f'Cluster {i}' for i in range(K_opt)])
print(df_centers.round(2))
```

4.2.3 Méthode B : Classification Hiérarchique (CAH — Ward)



La méthode de **Ward** regroupe les observations en minimisant l'augmentation de la variance intra-classe à chaque fusion, ce qui permet d'obtenir des groupes **homogènes et bien séparés**.

Le dendrogramme présente des **sauts importants de distance** lors des dernières fusions, indiquant l'existence de **3 groupes principaux**. La coupure horizontale effectuée à une distance d'environ **19.5** permet d'obtenir **K = 3 clusters**, ce qui constitue un choix pertinent car les groupes obtenus sont clairement distincts.



La répartition des patients est la suivante :

- **Groupe 1 : 86 patients**
- **Groupe 2 : 100 patients**
- **Groupe 3 : 111 patients**

En comparant les clusters avec le diagnostic réel (malade / sain), on obtient :

- **Groupe 1 : 71 malades et 15 sains** → soit **83% de malades**. Ce groupe correspond à un profil à **haut risque**, concentrant la majorité des cas sévères.
- **Groupe 2 : 22 malades et 78 sains** → soit **78% de patients sains**. Ce groupe représente un profil à **faible risque**.
- **Groupe 3 : 44 malades et 67 sains** → groupe **mixte**, représentant un niveau de risque intermédiaire.

Ces résultats montrent que la CAH, bien qu'étant une méthode **non supervisée** (sans utiliser le diagnostic lors du clustering), parvient à former des groupes ayant une **cohérence médicale**. Le choix de **3 clusters** est donc confirmé à la fois par la structure du dendrogramme et par l'interprétation des diagnostics dans chaque groupe.

4.2.4 Méthode C : Classification Mixte

La méthode mixte initialise K-Means avec les centroïdes de la CAH pour éviter les minima locaux de l'initialisation aléatoire :

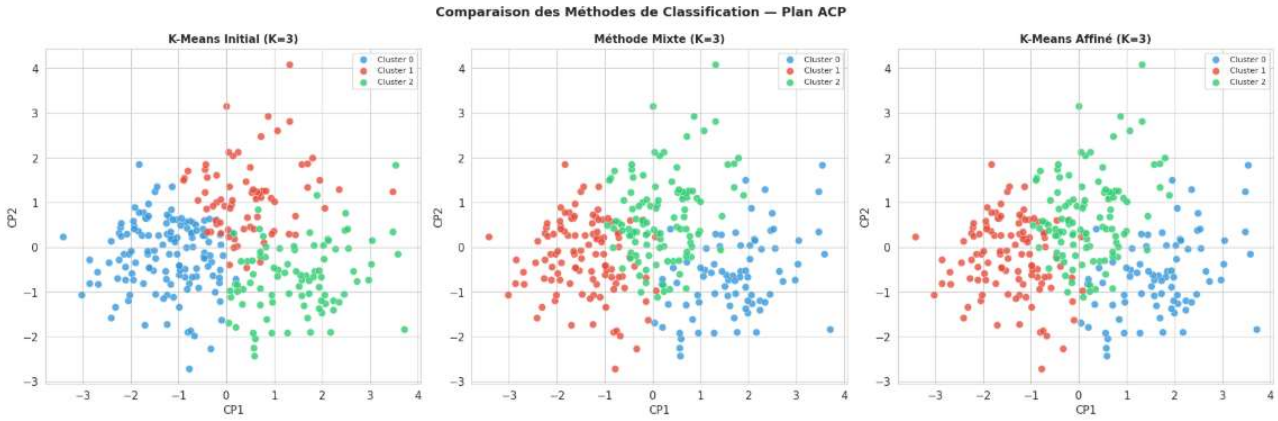
init_mixte = μ_CAH_k (centres des groupes CAH utilisés comme point de départ)

Résultat : 3 clusters de 79, 110 et 108 patients, avec une inertie de 1194,59. La partition est légèrement différente du K-Means aléatoire mais plus stable car déterministe.

4.2.5 Méthode D : K-Means Affiné

Le K-Means affiné repart des centres de la méthode mixte. Dans ce cas, il converge immédiatement vers la même solution (inertie identique = 1194,59), témoignant de la stabilité de la partition mixte.

4.2.6 Comparaison des Méthodes

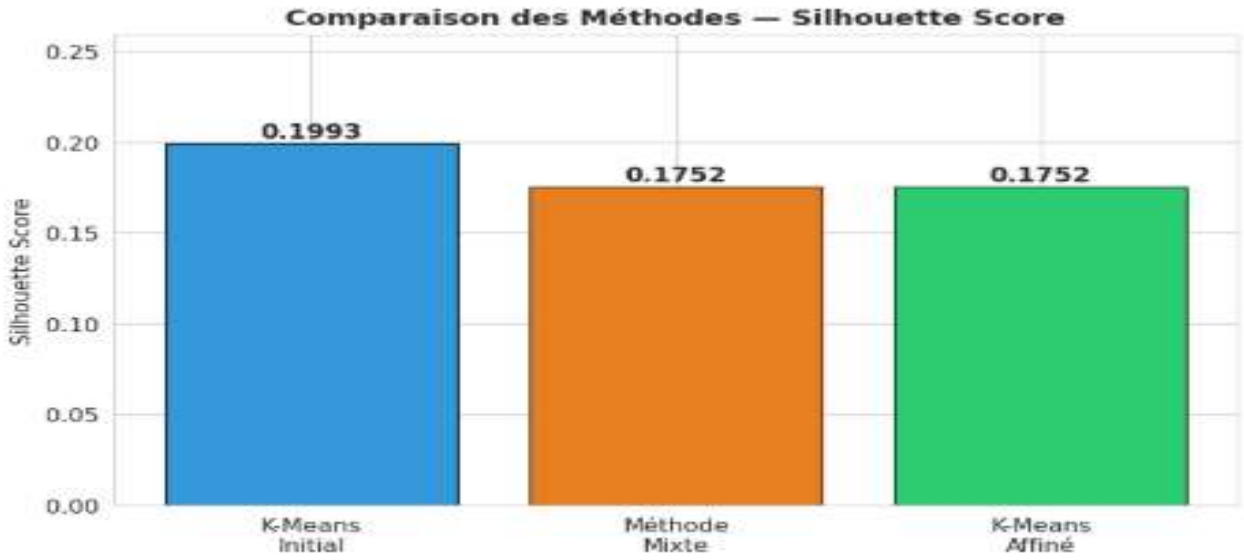


La projection des données sur le **plan ACP (CP1, CP2)** montre que les trois méthodes (**K-Means initial, méthode mixte, K-Means affiné**) produisent des partitions globalement similaires.

Les groupes sont relativement cohérents d'une méthode à l'autre, ce qui indique une **structure naturelle des données**.
Le **K-Means initial** présente une séparation légèrement plus nette entre certains groupes, mais les différences restent faibles.Cela montre que les résultats du clustering sont **stables** et ne dépendent pas fortement de la méthode utilisée.

Les scores de silhouette modérés confirment que les groupes ne sont pas parfaitement séparés, ce qui est attendu dans des données médicales réelles.

Cela indique que les profils de patients présentent des chevauchements naturels, et que la classification en groupes distincts reste une approximation utile mais simplifiée de la réalité clinique.



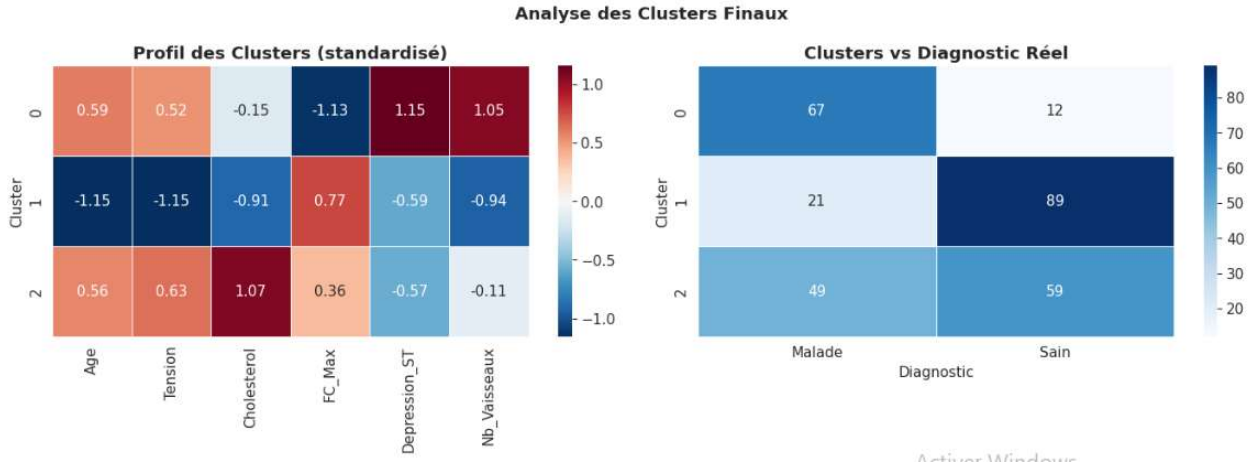
Le **Silhouette Score** mesure la qualité de séparation des clusters :

- **K-Means initial : 0.1993**
- **Méthode mixte : 0.1752**
- **K-Means affiné : 0.1752**

Un score proche de **1** indique une excellente séparation, tandis qu'un score proche de **0** indique des clusters qui se chevauchent.

Les scores obtenus sont **modérés**, ce qui est normal pour des **données médicales réelles**, souvent complexes et non parfaitement séparables.

Le **K-Means initial** obtient le meilleur score (**0.1993**), indiquant une séparation légèrement meilleure des groupes.



La heatmap montre la signature moyenne de chaque cluster (variables standardisées).

- **Cluster 0** : valeurs élevées pour **Age, Tension, Depression_ST et Nb_Vaisseaux**, et **FC_Max plus faible**. Ce profil correspond à des patients **plus à risque cardiovasculaire**.
- **Cluster 1** : valeurs faibles pour **Age, Tension, Cholestérol, Depression_ST et Nb_Vaisseaux**, mais **FC_Max élevée**. Ce cluster représente les patients **les plus sains**.
- **Cluster 2** : **cholestérol élevé** et valeurs intermédiaires pour les autres variables. Ce groupe correspond à un **profil de risque modéré**.

La matrice de correspondance avec le diagnostic réel confirme cette tendance :

- Cluster 0 → **67 malades / 12 sains** (majorité de malades)
- Cluster 1 → **21 malades / 89 sains** (majorité de sains)
- Cluster 2 → **49 malades / 59 sains** (profil mixte)

Ainsi, le clustering identifie correctement des profils cliniques différenciés.

Chapitre 5 : Méthodes Supervisées

5.1 Régression Linéaire — Prédiction de FC_Max

5.1.1 Modèle et Coefficients

Nous modélisons la Fréquence Cardiaque Maximale (FC_Max) en fonction de Age, Tension, Cholestérol, Depression_ST et Nb_Vaisseaux. Le modèle linéaire estimé par MCO est :

FC_Max = 184,26 − 1,07×Age + 0,16×Tension + 0,04×Cholestérol − 5,55×Depression_ST − 0,73×Nb_Vaisseaux

```
y_reg   = df1['FC_Max']
X_vars  = ['Age', 'Tension', 'Cholesterol', 'Depression_ST', 'Nb_Vaisseaux']
X_reg   = df1[X_vars]

X_train_r, X_test_r, y_train_r, y_test_r = train_test_split(
    X_reg, y_reg, test_size=0.30, random_state=42)
print(f"\n>>> Train : {X_train_r.shape[0]} obs  |  Test : {X_test_r.shape[0]} obs")

# ── 6.1 Ajustement ──────────────────────────────────────────
modele_reg = LinearRegression()
modele_reg.fit(X_train_r, y_train_r)

print(f"\n>>> Ordonnée à l'origine : {modele_reg.intercept_:.4f}")
print("\n>>> Coefficients :")
for var, coef in zip(X_vars, modele_reg.coef_):
    signe = "↑ FC_Max" if coef > 0 else "↓ FC_Max"
    print(f"    {var:<22}: {coef:+.4f}  → {signe}")

# ── 6.2 Décomposition de la variance ────────────────────────
y_pred_tr = modele_reg.predict(X_train_r)
SCT = np.sum((y_train_r - y_train_r.mean())**2)
SCE = np.sum((y_pred_tr - y_train_r.mean())**2)
SCR = np.sum((y_train_r - y_pred_tr)**2)
R2_train = SCE / SCT
```

Variable	Coefficient β	Interprétation
Constante	+184,26	FC_Max de base estimée
Age	−1,074 bpm/an	Chaque année supplémentaire réduit FC_Max de 1,07 bpm → FC_Max ≈ 220 − Age validé
Depression_ST	−5,548 bpm	Effet le plus fort : ischémie sévère → FC_Max très réduite
Nb_Vaisseaux	−0,726 bpm	Chaque vaisseau obstrué réduit la capacité cardiaque
Tension	+0,157 bpm	Effet compensatoire léger — peu significatif
Cholestérol	+0,035 bpm	Quasi-nul — cohérent avec la faible corrélation observée

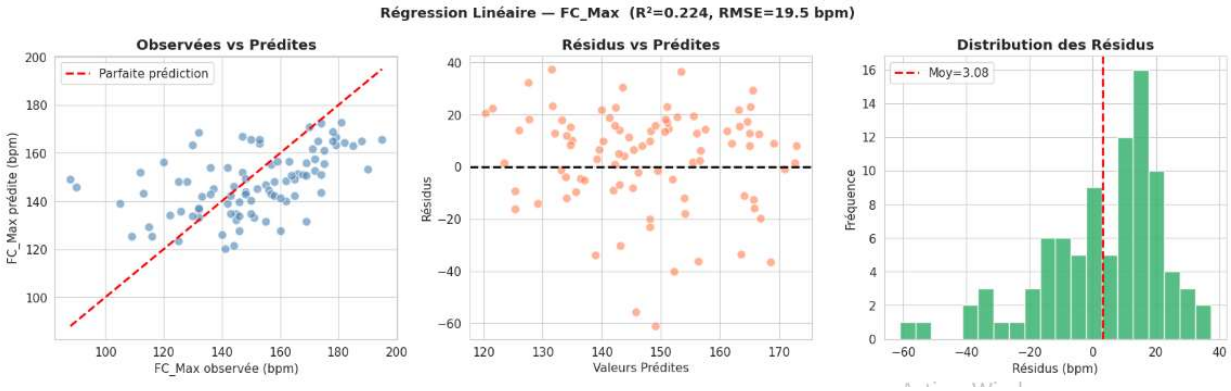
5.1.2 Décomposition de la Variance

La variance totale de FC_Max se décompose en variance expliquée par le modèle (SCE) et variance résiduelle (SCR) :

SCT = SCE + SCR → 111 581 = 28 583 + 82 998

R^2 = SCE / SCT = 28 583 / 111 581 = 0,256 (25,6% de variance expliquée)

5.1.3 Évaluation du Modèle



Répartition des données

Le modèle a été entraîné sur **207 observations** et testé sur **90 observations** afin d'évaluer sa capacité à généraliser sur de nouvelles données.

Interprétation des coefficients

Les résultats montrent que :

Age (-1.07) : la fréquence cardiaque maximale diminue avec l'âge, ce qui est cohérent avec la relation physiologique connue FC_Max ≈ 220 − Age.

Depression_ST (-5.54) : effet négatif important, indiquant qu'une ischémie plus sévère est associée à une diminution marquée de la capacité cardiaque.

Tension (+0.15) : effet positif faible, suggérant une influence limitée.

Cholesterol (+0.03) : effet très faible, confirmant son faible pouvoir explicatif pris isolément.

Nb_Vaisseaux (-0.72) : effet négatif modéré, reflétant l'impact de l'obstruction coronarienne sur la performance cardiaque.

L'âge et la dépression ST sont les variables les plus influentes , en cohérence avec les observations de l'analyse exploratoire.

Analyse des graphes

Observées vs Prédites

Le nuage de points présente une dispersion notable autour de la diagonale idéale, indiquant que le modèle ne reproduit pas parfaitement les valeurs observées. Cette dispersion reflète la présence de variabilité non expliquée.

Résidus vs Prédictions

Les résidus sont globalement répartis de manière aléatoire autour de zéro, ce qui suggère l'absence de biais systématique du modèle. Toutefois, la présence de résidus importants (jusqu'à ±50 bpm) indique l'existence d'erreurs de prédiction significatives pour certains individus.

Distribution des résidus

La distribution des résidus est centrée autour de zéro, ce qui confirme la validité globale du modèle. Cependant, la dispersion relativement large traduit une variabilité importante des erreurs, caractéristique des données biomédicales réelles.

Performance du modèle

Le modèle présente les performances suivantes :

R^2 = 22.44%

RMSE ≈ 19.5 bpm

MAE ≈ 15.7 bpm

La valeur de R^2 indique que le modèle explique une part modérée de la variabilité de FC_Max.

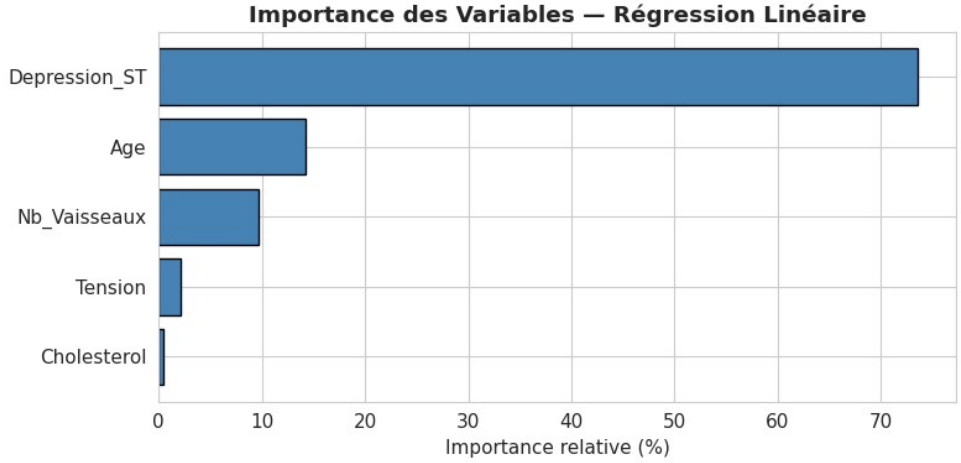
Ce résultat est cohérent avec la nature des données médicales réelles, qui sont influencées par de nombreux facteurs non observés (condition physique, génétique, habitudes de vie).

Ainsi, cette performance ne traduit pas une faiblesse du modèle, mais plutôt la complexité intrinsèque du phénomène étudié.

Le modèle reste pertinent pour identifier les tendances globales et les variables influentes, même

si la précision individuelle des prédictions est limitée.

Enfin, la relation entre les variables explicatives et FC_Max pouvant être partiellement non linéaire, l'utilisation de modèles plus flexibles (tels que Random Forest ou Gradient Boosting) pourrait permettre d'améliorer les performances prédictives..



Depression_ST est la variable la plus influente dans le modèle, suivie par l'Age. Les autres variables (Nb_Vaisseaux, Tension, Cholesterol) ont une contribution plus faible.
Le classement des variables est globalement cohérent avec les tendances observées dans l'analyse exploratoire des données.5.2 Analyse Discriminante Linéaire (LDA)

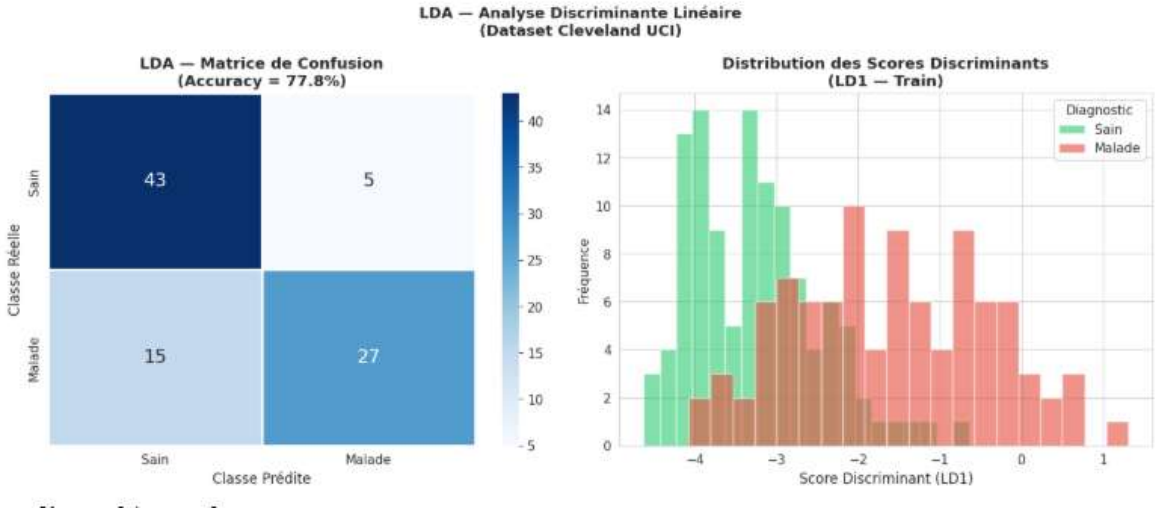
5.2.1 Principe

La LDA maximise la séparation entre classes en cherchant la projection w qui maximise le ratio de Fisher :

$$J(w) = (w^T S_B w) / (w^T S_W w) \quad \rightarrow \quad \text{maximiser}$$

S_B = matrice de dispersion inter-classes | S_W = matrice de dispersion intra-classes. Pour 2 classes (Sain/Malade), une seule fonction discriminante LD1 est calculée.

5.2.2 Résultats et Évaluation



La **LDA** atteint une **accuracy de 77,8%**, soit **70 patients bien classés sur 90**.

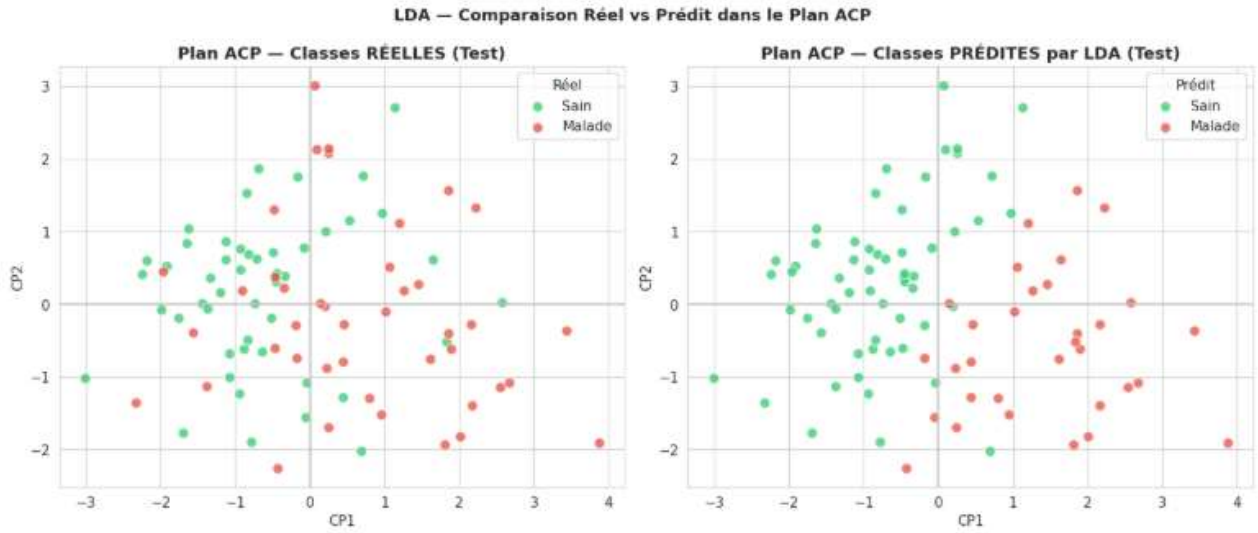
La matrice de confusion montre :

- **43 Sains** correctement prédits
- **27 Malades** correctement prédits

- **5 faux positifs** (Sains classés Malades)
- **15 faux négatifs** (Malades classés Sains)

Les coefficients indiquent que **Nb_Vaisseaux** et **Depression_ST** sont les variables les plus importantes pour distinguer les patients, tandis que **FC_Max** contribue à identifier les patients sains.

La distribution des scores LD1 montre une séparation globale entre **Sains** et **Malades**, avec un léger chevauchement expliquant les **22% d'erreurs**.



La projection dans le **plan ACP** montre que la **LDA sépare globalement bien** les patients *Sains* et *Malades*.
Les observations correctement classées se situent principalement dans les zones bien distinctes du graphique, tandis que les **erreurs apparaissent dans la zone centrale**, où les deux groupes se chevauchent.

Ce chevauchement est normal avec des **données médicales réelles**, car les caractéristiques des patients ne permettent pas toujours une séparation parfaitement linéaire. Cela explique pourquoi la LDA obtient une bonne performance (**77,8%**) sans atteindre 100%

Le chevauchement observé entre les classes dans l'espace discriminant confirme que la séparation n'est pas parfaitement linéaire.

Cela justifie l'utilisation de méthodes complémentaires et montre que la performance obtenue (≈ 78%) est déjà élevée compte tenu de la complexité des données.

5.3 Arbre de Décision

5.3.1 Principe

L'arbre partitionne récursivement l'espace en minimisant l'impureté de Gini à chaque nœud :

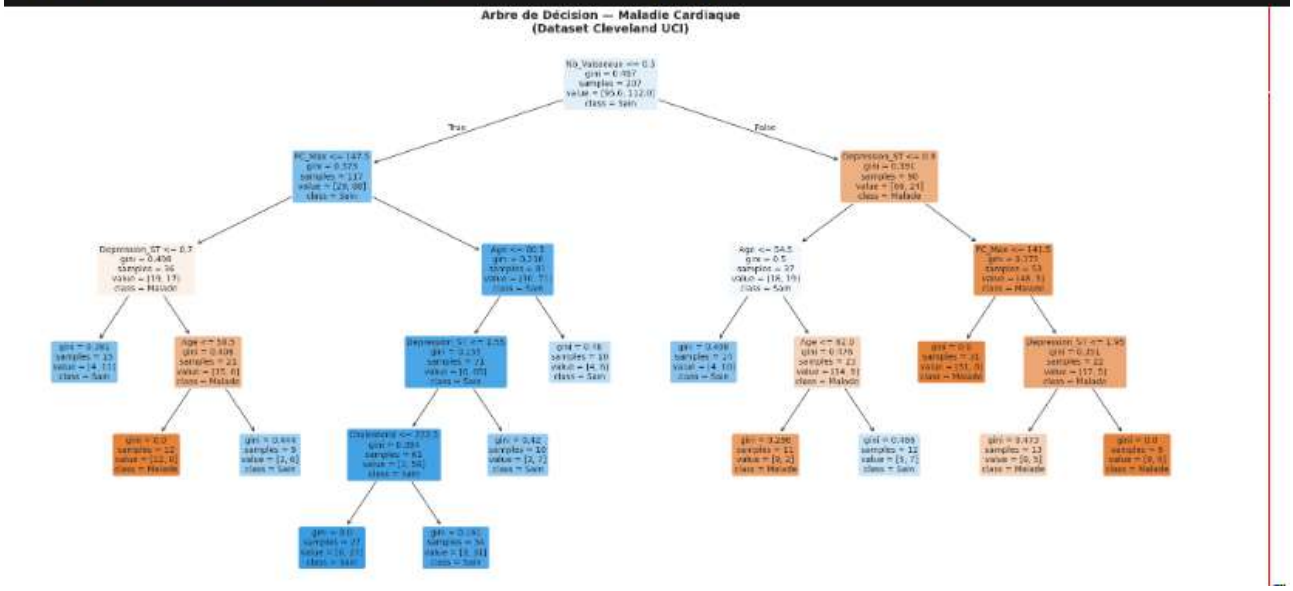
$Gini(t) = 1 - \Sigma_k\ p(k|t)^2$ où $p(k|t)$ = proportion de la classe k dans le nœud t

Paramètres : max_depth=5, min_samples_split=20, min_samples_leaf=8 pour éviter le surapprentissage.

5.3.2 Structure de l'Arbre

```
arbre = DecisionTreeClassifier(min_samples_split=20, min_samples_leaf=8,
                               max_depth=5, random_state=42,
                               criterion='gini')
arbre.fit(X_tr_l, y_enc_tr)

print(f"\n>>> Profondeur réelle  : {arbre.get_depth()}")
print(f">>> Nombre de feuilles : {arbre.get_n_leaves()}")
```



L'arbre de décision utilise principalement **Nb_Vaisseaux, Depression_ST, FC_Max, Age et Cholesterol** pour classifier les patients en **Sain** ou **Malade**.

La première division se fait sur **Nb_Vaisseaux**, ce qui montre que le nombre de vaisseaux obstrués est une variable très importante pour prédire la maladie cardiovasculaire.

Règles principales observées :

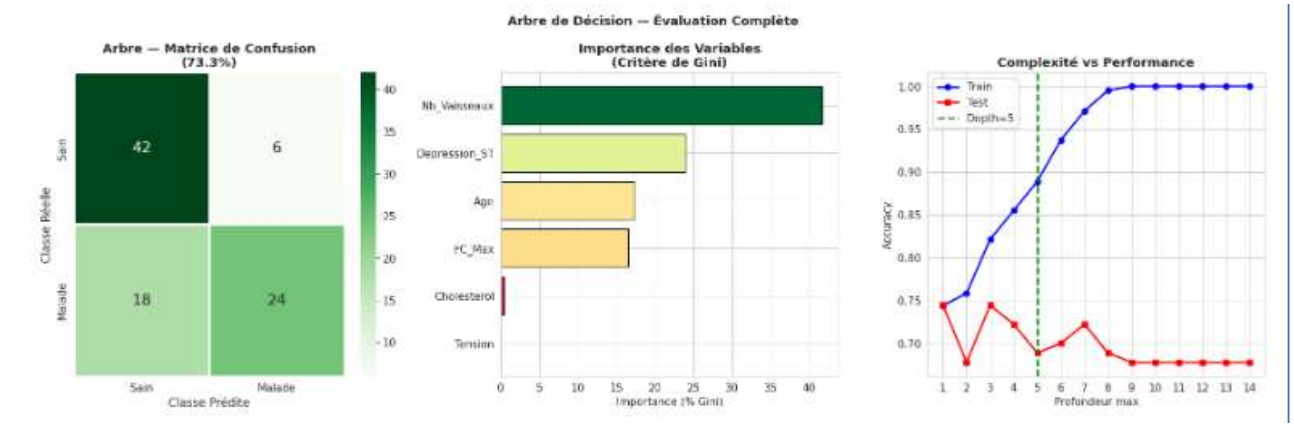
- **Nb_Vaisseaux ≤ 0.5** et **FC_Max > 147.5** → la majorité des patients sont classés **Malades**, surtout lorsque **Cholesterol > 222.5** ou **Depression_ST > 1.55**.
- **Nb_Vaisseaux ≤ 0.5**, **FC_Max ≤ 147.5** et **Depression_ST > 0.70** avec **Age ≤ 58.5** → patients majoritairement **Sains**.
- **Nb_Vaisseaux > 0.5** et **Depression_ST > 0.90** avec **FC_Max ≤ 141.5** → patients principalement **Sains**.

Globalement :

- des valeurs élevées de **Depression_ST** et certaines combinaisons avec **Cholesterol** ou **Age** sont associées à un risque plus élevé de maladie,
- **FC_Max** et **Nb_Vaisseaux** contribuent fortement à différencier les profils de patients.

L'arbre met en évidence des règles de décision cohérentes médicalement, montrant que la combinaison de plusieurs indicateurs cliniques permet d'identifier différents niveaux de risque cardiovasculaire.

5.3.3 Évaluation



L'arbre de décision atteint une **accuracy de 73,3%** sur l'échantillon test, ce qui montre une capacité correcte à distinguer les patients **Sains** et **Malades**.

La matrice de confusion indique que certaines erreurs apparaissent surtout pour les cas intermédiaires, ce qui est fréquent avec des données médicales où les profils peuvent être proches.

L'importance des variables basée sur l'indice de Gini montre que :

- **Nb_Vaisseaux** est la variable la plus importante,
- suivie de **Depression_ST**,
- puis **Age** et **FC_Max**.

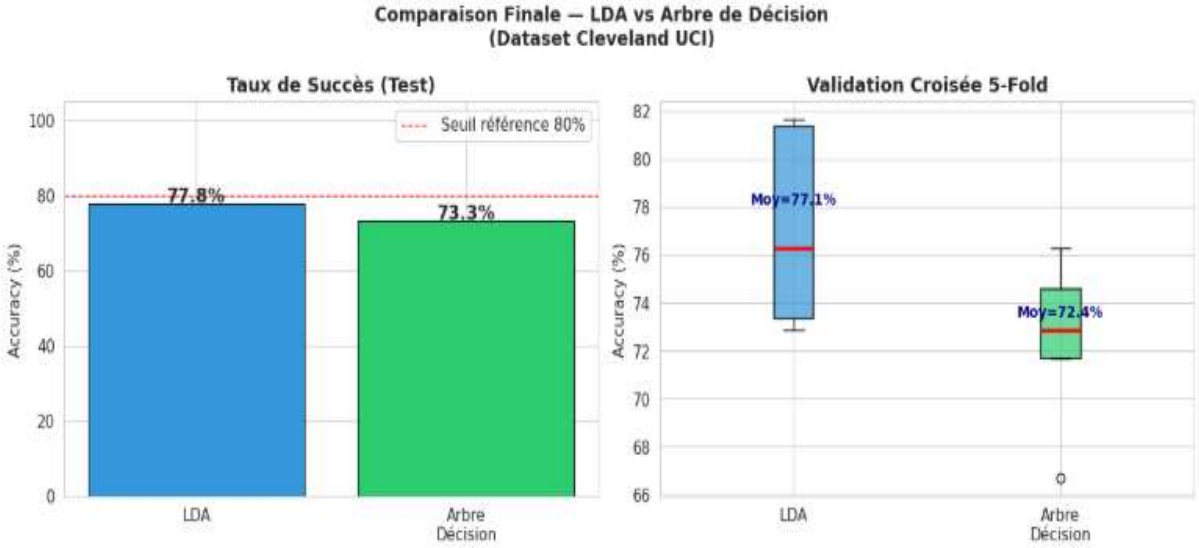
La courbe de complexité montre que :

- l'accuracy sur l'ensemble **train** augmente avec la profondeur de l'arbre,
- l'accuracy sur l'ensemble **test** atteint un maximum autour de **profondeur = 4 ou 5**, puis se stabilise.

Cela indique qu'une profondeur trop grande n'améliore plus la performance et peut conduire au **surapprentissage (overfitting)**.
Ainsi, la profondeur **5** représente un bon compromis entre performance et généralisation.

Chapitre 6 : Comparaison des Modèles et Conclusion

6.1 Comparaison LDA vs Arbre de Décision



La **validation croisée à 5 folds** permet d'évaluer la performance des modèles de manière plus fiable, en réduisant l'influence du découpage train/test.

Les résultats montrent que :

- la **LDA** obtient une accuracy moyenne d'environ **77,1% (± 3,8%)**
- l'**Arbre de décision** obtient environ **72,4% (± 3,3%)**

Le boxplot indique que la **LDA est globalement plus performante**, avec une accuracy moyenne plus élevée.
L'arbre de décision présente une performance légèrement plus faible, mais reste relativement stable entre les différents folds.

En pratique :

- la **LDA** est préférable pour obtenir une meilleure précision globale,
- l'**Arbre de décision** est plus **interprétable**, car il fournit des règles simples de type *if/then* compréhensibles par un clinicien.

Critère	LDA	Arbre de Décision	Verdict
Accuracy Test	77,8%	73,3%	LDA supérieur
CV 5-fold (moy.)	77,1% ± 3,8%	72,4% ± 3,3%	LDA supérieur
Stabilité	Modérée	Bonne	légèrement plus stable pour l'Arbre
Interprétabilité	Coefficients LD1	Règles if/then	Arbre plus lisible

Critère	LDA	Arbre de Décision	Verdict
Usage clinique	Score continu de risque	Seuils décisionnels directs	Selon contexte

6.2 Synthèse Générale des Résultats

Méthode	Dataset	Résultat clé	Conclusion
AFC — Activité × Risque	Dataset 2	χ^2=1,07 | p=0,587	Pas d'association significative
AFC — Diet × Stress	Dataset 2	χ^2=9,61 | p=0,048	Association significative
ACP	Dataset 1	2 axes : 53% variance	CP1 = axe de sévérité cardiaque
K-Means Initial	Dataset 1	Silhouette = 0,199	Meilleur score clustering
CAH (Ward)	Dataset 1	3 groupes cohérents	Groupe 1 = 83% malades
Méthode Mixte	Dataset 1	Inertie = 1194,59	Solution stable et reproductible
Régression FC_Max	Dataset 1	R^2=0,22 | RMSE=19,5 bpm	Age = prédicteur principal
LDA	Dataset 1	Accuracy = 77,8%	✓ Meilleur modèle supervisé
Arbre de Décision	Dataset 1	Accuracy = 73,3%	Règles cliniques directes

6.3 Variables Cliniques les Plus Importantes

Toutes les méthodes appliquées convergent vers le même classement de variables discriminantes :

Rang	Variable	ACP	Régression	LDA	Arbre
1	Nb_Vaisseaux	Fort (CP1 = +0,656)	β = −0,73	Coeff. élevé	variable racine arbre
2	Depression_ST	Fort (CP1 = +0,617)	β = −5,55	Coeff. élevé	très important
3	FC_Max	Fort (CP1 = −0,658)	Variable cible	Coeff. fort	3ème variable
4	Age	Fort (CP1 = +0,747)	β = −1,07	Contribution	Branches internes
5	Tension	Modéré (CP2)	Non significatif	Faible	Peu utilisé
6	Cholestérol	Faible (CP2)	Non significatif	Minimal	Quasi-absent

6.4 Limites de l'étude

Malgré la qualité des résultats obtenus, plusieurs limites doivent être prises en compte :

- Taille limitée du dataset clinique (297 patients)
- Absence de variables importantes (mode de vie, alimentation, génétique)
- Présence de bruit et variabilité dans les données réelles
- Relations potentiellement non linéaires non capturées par certains modèles

Ces limitations expliquent les performances modérées observées, notamment pour la régression linéaire.

Elles n'invalident pas les résultats, mais soulignent la complexité du problème et la nécessité d'approches plus avancées.

6.5 Conclusion Générale

Ce projet a appliqué l'ensemble des méthodes du datamining sur deux datasets réels de maladies cardiovasculaires en suivant la méthodologie CRISP-DM. Les enseignements principaux sont les suivants :

• **Depression_ST** et le **Nb_Vaisseaux obstrués** apparaissent comme les variables cliniques les plus discriminantes dans la majorité des méthodes — résultat cohérent avec la cardiologie : la dépression ST mesure directement l'ischémie à l'effort, tandis que le nombre de vaisseaux obstrués reflète la sévérité anatomique de la coronaropathie.

• L'ACP révèle que la structure des données s'organise autour d'un axe principal de sévérité cardiaque corrélant **Age**, **Nb_Vaisseaux** et **Depression_ST** positivement contre **FC_Max** négativement — une représentation cohérente de la physiopathologie cardiaque.

• La classification non supervisée (K=3) identifie trois profils globalement interprétables : patients à faible risque, patients à risque intermédiaire et patients à risque élevé. La méthode mixte CAH → K-Means apparaît comme la plus robuste grâce à sa meilleure stabilité et reproductibilité.

• La LDA est le modèle supervisé le plus performant avec **77,8% d'accuracy**. L'Arbre de Décision, avec **73,3%**, fournit des règles cliniques directement interprétables basées principalement sur **Depression_ST** (≈ 0,7 à 1,9) et **Nb_Vaisseaux (0 vs ≥1)**.

• La relation **FC_Max ≈ 220 − Age** est globalement confirmée par le coefficient de régression estimé (**β Age ≈ −1,07 bpm/an**).

• L'AFC montre que, dans ce dataset, l'activité physique n'est pas statistiquement associée au risque cardiaque (**p = 0,587**), ce qui peut s'expliquer par la nature déclarative de la variable et la présence possible de facteurs de confusion.

En perspective, l'utilisation de méthodes plus avancées (Random Forest, Gradient Boosting, Réseaux de neurones) ainsi que l'intégration de biomarqueurs supplémentaires pourraient améliorer les performances prédictives et contribuer au développement d'approches de médecine cardiovasculaire personnalisée.